

2026-1 기계학습기초 Team 2 Final Report

15 분 경기 상태 기반 League of Legends 랭크 솔로 서렌 패배 및 Dead Game 위험 분석

팀장: 정민기 | 팀원: 송재혁, 손범준, 양승범

아주대학교 인공지능융합학과

제출일: 2026 년 6 월 12 일

Abstract. 본 프로젝트는 Riot API 로 수집한 League of Legends 한국 서버 랭크 솔로/듀오 데이터를 이용하여, 경기 시작 후 15 분 시점의 팀 단위 상태가 일반 서렌 패배와 최종 패배 위험을 어떻게 설명하는지 분석한다. 초기 문제는 `team\_surrendered` 이진 분류였으며, 2,525 경기에서 생성된 5,050 개 match-team row 중 서렌 패배 row 는 870 개(17.23%)였다. 데이터 계약상 15 분 feature 는 11 개이며, 종료 후 확정되는 `game\_duration\_sec` 는 metadata 로만 다루고 모델 feature 에서 제외하였다. 초기 서렌 label 에서는 tuned Random Forest 가 test F1 0.522, precision 0.438, recall 0.647 을 보였지만, 서렌은 경기 상태 외에도 팀 분위기와 유저 의사결정이 섞인 행동 label 이므로 고성능 예측에는 한계가 있었다. 후속 실험에서는 target 을 최종 패배(`final\_loss`)로 분리하고, 10 개 selected/non-zero feature 를 가진 compact L1 Logistic Regression 및 interaction L1 모델을 통해 Dead Game 위험을 설명했다. 최종 해석은 “15 분에 서렌을 추천하는 모델”이 아니라, 게임 길이 단축과 포기감 완화 패치 방향을 논의하기 위한 설명 가능한 15 분 위험 신호 분석이다.¹

Keywords: League of Legends, Riot API, surrender prediction, final-loss risk, Dead Game, early-game features, class imbalance, Logistic Regression, Random Forest, explainability

1. INTRODUCTION

League of Legends 는 한 판이 길고, 초반 손해가 누적되면 유저가 “이미 게임이 끝났다”고 느끼는 구간이 생길 수 있다. 최근 Riot 의 Swiftplay 는 전통적인 소환사의 협곡 흐름은 유지하되 더 빠르고 덜 부담스러운 경험을 목표로 한다. 이와 같은 패치 방향은 단순히 평균 게임 시간을 줄이는 문제가 아니라, 불리한 게임이 의미 없이 오래 끌리는 체감 시간을 줄이고, 뒤쳐진 팀에게 다시 플레이할 이유를 제공하는 문제와 연결된다.²

본 프로젝트는 이 문제를 데이터 관점에서 다룬다. 초기 목표는 15 분 팀 상태로 일반 서렌 패배(`team\_surrendered`)를 예측하는 것이었다. 그러나 최신 저장소 정리 과정에서 서렌 label 은 희소하고 행동 noise 가 크다는 한계를 확인했으며, 최종 분석은 `team\_surrendered` baseline 과 `final\_loss` / Dead Game 위험 분석을 분리하는 방향으로 정리했다.

본 보고서의 핵심 기여는 세 가지이다. 첫째, Riot match/timeline 데이터를 15 분 기준 match-team row 로 변환하고 11 개 canonical feature 를 정의했다. 둘째, `game\_duration\_sec` 와 같은 종료 후 metadata 가 모델 입력에 섞이지 않도록 15 분-only feature 계약을 고정했다. 셋째, 서렌 행동 label 의 한계와 최종 패배 위험 label 의 설명력 차이를 시각화와 정량 지표로 제시했다.

본 보고서의 분석 구조는 두 단계로 구성되며, 두 target 은 직접 성능 비교 대상이 아니라 서로 다른 질문에 답한다.

구분	Target	목적
1 단계	`team_surrendered`	서렌 행동 label 의 baseline 확인
2 단계	`final_loss`	15 분 상태 기반 Dead Game 위험 설명

2. RELATED WORK / BACKGROUND

본 프로젝트는 지도학습 기반 이진 분류 문제이다. 수업 자료에서 강조한 것처럼 공정한 모델 평가는 훈련에 쓰지 않은 테스트 세트로 수행해야 하며, 클래스가 불균형할 때에는 단순 accuracy 만으로 결론을 내리면 안 된다. 따라서 본 프로젝트도 `match\_id` 기준 group split 으로 같은 경기의 양 팀 row 가 서로 다른 split 에 들어가지 않도록 했다.

모델 배경은 수업 범위의 Logistic Regression 과 Random Forest 를 중심으로 한다. Logistic Regression 은 선형 방정식과 확률 출력을 통해 분류를 수행하므로 계수 해석이 쉽고, Random Forest 는 여러 decision tree 의 앙상블로 비선형 feature 상호작용을 일부 포착할 수 있다. 후속

¹Team 2 GitHub repository and final report notebooks: Riot API Match-V5 match/timeline data were transformed into 15-minute match-team rows.

²Riot Games, “/dev: Introducing Swiftplay,” 2024-11-25. The article describes Swiftplay as a faster Summoner’s Rift queue that softens early disadvantages.

실험에서 XGBoost/LightGBM/KMeans interaction 과 MLP 신경망도 검토했지만, 최종 본문은 설명 가능한 L1 Logistic Regression 계열을 중심으로 해석한다.

게임 디자인 배경에서는 Objective Bounties 와 respawning Nexus Turrets 가 중요하다. Objective Bounties 는 뒤처진 팀이 오브젝트를 획득했을 때 추가 골드를 주는 comeback 장치이며 XP, gold, dragon, turret lead 를 기준으로 계산된다. Respawnning Nexus Turrets 는 두 넥서스 포탑을 잃었다는 이유만으로 게임이 절망적으로 느껴지는 상황을 줄이려는 패치 의도를 가진다. 따라서 15 분 골드, 타워, 드래곤 격차를 분석하는 본 프로젝트는 패치 방향 해석과 직접 연결된다.

기존 esports/MOBA 승부예측 연구는 주로 승패 자체를 맞히는 문제에 집중해 왔다. Hodge et al.은 MOBA 경기의 mixed-rank match data 로 professional match outcome 을 예측할 수 있음을 보였고, Do et al.은 League of Legends ranked game 에서 champion 선택 이후 player-champion experience 만으로도 outcome prediction 이 가능하다고 보고했다. 또한 Junior and Campelo 는 League of Legends real-time result prediction 에서 경기 단계별 변수를 사용했고, early stage 에서는 Logistic Regression 과 Gradient Boosting 계열이 유효한 후보가 될 수 있음을 보였다. Wilathgamuwa 는 early-game 데이터 기반 EDA 와 승리 예측에서 킬 포탑 지표의 설명력을 비교했다.

본 프로젝트는 이러한 승부예측 연구와 달리 입력을 15 분 단일 cutoff 로 제한하고, 예측 대상을 `team\_surrendered` 행동 label 과 `final\_loss` 결과 label 로 분리한다. 따라서 목표는 승패 예측 정확도를 최대화하는 것이 아니라, 어떤 label 이 15 분 상태로 더 안정적으로 설명되는지와 그 해석 범위를 구분하는 데 있다.

기존 연구와 본 프로젝트의 차이를 정리하면 다음과 같다.

연구	Target	입력 시점	본 프로젝트와의 차이
Hodge et al. 2017	프로 경기 승패	경기 전/진행 정보	프로 mixed-rank 승패 중심, 행동 label 없음
Do et al. 2021	랭크 승패	champion select 직후	사전 속련도 feature, 인게임 상태 미사용
Junior & Campelo 2023	실시간 승패	경기 단계별 연속	연속 시점 예측, 단일 cutoff 아님
Wilathgamuwa 2024	early-game 승패	early-game 지표	승패 target, 서렌/final-loss 분리 없음
Team 2 (본 연구)	surrender / final_loss 분리	15 분 단일 cutoff	행동 label 과 결과 label 의 설명력 구분

3. DATASET AND FEATURE CONTRACT

3.1 Data contract

분석 단위는 “한 경기의 한 팀”이다. 조건을 만족하는 경기 하나에서 블루 팀(`team\_id=100`)과 레드 팀(`team\_id=200`) 두 row 를 만들고, 모든 `\*\_diff\_15` feature 는 `this\_team\_value - opponent\_team\_value`로 계산한다. 라벨 `team\_surrendered=True`는 해당 팀이 패배 팀이고 참가자 중 일반 서렌 종료 플래그가 존재하는 경우로 정의한다.³

데이터 출처는 Riot Developer Portal 의 Match-V5 match/timeline API 이다. 수집 대상은 한국 서버 Ranked Solo/Duo(`queue\_id=420`)이며, `riot-scale-2600` 실행 산출물 기준 생성 시각은 2026-05-14 19:59:29 UTC 이다. 수집 seed 는 EMERALD I 랭크 솔로 유저 목록 기준(최대 200 명, seed 별 match id 최대 20 개, unique match 최대 2,600 개)이며, seed 방식 수집이므로 모든 참가자의 티어가 Emerald 이상임을 보장하지는 않는다. 또한 900 초 미만 경기와 조기 서렌/리메이크성 경기(`gameEndedInEarlySurrender`)는 제외하여 일반 서렌 패배만 라벨로 사용했다. 공개 보고서에는 팀 단위 집계 feature 만 남겼고 PUUID, 소환사명, Riot ID, API key, Supabase key 는 포함하지 않았다. 수집과 활용은 Riot Developer Portal 약관 범위의 비상업적 교육·연구 목적으로 한정했다.

후속 `final\_loss` 분석에 사용한 `data\_3`는 같은 2,525 경기/5,050 match-team row 구조를 유지하되, v16.9 단일 패치 정합과 Lolalytics 16.9 champion-position prior 를 보강한 데이터이다. 여기서 `game\_length`라는 이름의 외부 prior 는 현재 match 의 실제 경기 시간이 아니라 champion-position 별 시간대 승률 profile 이므로, `game\_duration\_sec`와 같은 종료 후 정보와 구분했다. 외부 prior 의 출처는 Lolalytics 공개 챔피언 통계(patch 16.9 집계)이며 References 에 표기했다.

³Team 2 docs/data_contract.md: each eligible match produces two team rows; features use the 15-minute frame or events with timestamp <= 900000 ms.

항목	값
match 수	2,525
team row 수	5,050
team_surrendered=True	870 rows
positive rate	17.23%
queue	Ranked Solo/Duo (`queue_id=420`)
기준 시점	15 분
초기 feature 수	11 개 canonical 15-minute features
후속 target	`final_loss` / Dead Game risk

Table 1. 데이터셋 요약과 target 정의. Positive rate 가 낮기 때문에 이후 평가는 accuracy 보다 F1, recall, PR-AUC 를 함께 본다.




Figure 1. 초기 `team\_surrendered` label 분포. Positive class 가 17.23%로 희소하므로 accuracy 만으로 모델을 평가하면 위험하다.

3.2 Canonical 11 features and leakage control

데이터 계약과 `src/team2\_surrender/modeling.py`의 `FEATURE\_COLUMNS` 기준, 15 분 canonical feature 는 11 개로 정의된다. 이 중 `rift\_herald\_diff\_15`는 이번 run 에서 all-zero 로 관측되어 실질 구분 신호는 10 개 수준이며, `game\_duration\_sec`는 종료 후 metadata 이므로 모델 입력에서 제외했다. 따라서 본문의 성능 표는 모두 15 분 이전에 관측 가능한 feature 만 사용한 결과로 해석한다.

Feature	의미
gold_diff_15	15 분 팀 총 골드 차이
kill_diff_15	15 분까지 챔피언 킬 차이
tower_diff_15	15 분까지 포탑 파괴 차이
dragon_diff_15	15 분까지 드래곤 처치 차이
rift_herald_diff_15	15 분까지 전령 차이; 이번 run 에서는 all-zero
cs_diff_15	15 분 CS 합 차이
avg_level_diff_15	15 분 팀 평균 레벨 차이
first_blood	15 분 전 선취점 방향
first_tower	15 분 전 첫 포탑 방향
ward_placed_diff_15	15 분까지 와드 설치 차이
ward_kill_diff_15	15 분까지 와드 제거 차이

Table 2. 15 분 canonical feature 목록. 모든 차이값은 this team minus opponent team 기준이다.




Figure 2. Feature count check. 데이터 계약 feature 는 11 개이고, compact L1 의 selected/non-zero feature 는 10 개이다. ``game_duration_sec``는 종료 후 metadata 이므로 15 분-only 모델 feature 에 포함하지 않는다.

4. APPROACH

전체 파이프라인은 Riot API 수집, raw match/timeline JSON 저장, 15 분 팀 단위 feature 생성, 데이터 계약 검증, group split, baseline 학습, threshold 조정, 그리고 ``final_loss`` 위험 분석으로 구성된다. 1 단계는 서렌 행동 label 의 기준선을 확인하고, 2 단계는 동일한 15 분 상태 신호가 최종 패배 위험을 얼마나 안정적으로 설명하는지 보는 구조이다. feature 는 15 분 participant frame 또는 timestamp 가 900,000ms 이하인 event 만 사용하며, 최종 승패, 경기 종료 시간, 15 분 이후 이벤트, 서렌 종료 플래그는 모델 입력에서 제외한다.

모델링은 두 단계로 진행했다. 1 단계에서는 ``team_surrendered``를 target 으로 Dummy, Logistic Regression, Random Forest, HistGradientBoosting 을 비교해 서렌 행동 label 의 baseline 을 확인했다. 2 단계에서는 ``final_loss``로 target 을 바꾸어 15 분 상태가 실제 최종 패배 위험을 얼마나 안정적으로 설명하는지 확인했다. 후속 모델은 복잡도를 높이는 방향보다 L1 규제와 scorecard 를 활용해 설명력을 유지하는 방향을 택했다.

5. EXPERIMENT

초기 데이터는 ``riot-scale-2600`` 산출물이며, train/validation/test split 은 ``match_id`` 기준 group split 을 사용했다. 한 경기의 두 팀 row 는 서로 반대 부호의 feature 를 가지므로, row 단위 random split 을 하면 같은 경기 정보가 train 과 test 에 동시에 들어가는 leakage 가 생길 수 있다. 따라서 같은 match 의 두 row 는 반드시 동일 split 에 배정했다.

실험 환경과 재현 설정은 표로 별도 고정했다. 핵심 원칙은 validation 에서 선택한 threshold 와 모델 후보를 hold-out test 에 한 번만 적용하고, 후속 final-loss 실험은 단일 seed 점수보다 multi-seed 평균과 표준편차를 함께 보는 것이다.

항목	설정
분석 단위	match-team row; 한 match 에서 blue/red 두 row 생성
분할 방식	<code>`match_id`</code> 기준 group split; 같은 경기의 두 row 는 같은 split
초기 target	<code>`team_surrendered`</code> ; positive rate 17.23%
후속 target	<code>`final_loss`</code> ; 한 경기당 패배 팀 1 행이 positive
평가 지표	Accuracy, Precision, Recall, F1, ROC-AUC, PR-AUC, confusion matrix
주요 모델	Dummy, Logistic Regression, Random Forest, HistGradientBoosting, L1 Logistic Regression, MLP(신경망)
Seed 관리	초기 baseline <code>`random_state=42`</code> ; compact L1 은 seeds 11-15 5-seed 평균(<code>`lab/09`</code>), interaction check 는 seeds 11/42/77 3-seed 평균(<code>`lab/14`</code>), 안정성 보조 검증은 seeds 10-19(<code>`lab/08`</code>)
주요 재현 파일	<code>`docs/data_contract.md`</code> , <code>`src/team2_surrender/modeling.py`</code> , <code>`lab/01`</code> ~ <code>`lab/14`</code>
의존성	<code>`requirements.txt`</code> : numpy, pandas, scikit-learn, matplotlib, jupyter 계열

Table 3. 실험 환경 및 재현 설정. 종료 후 정보와 15 분 이후 이벤트는 입력 feature 에서 제외했다.

하이퍼파라미터는 복잡한 탐색보다 해석 가능성과 재현성을 우선해 고정했다. 초기 baseline 의 `src/team2\_surrender/modeling.py`는 Logistic Regression `max\_iter=2000`, `class\_weight=balanced`, Random Forest `n\_estimators=300`, `min\_samples\_leaf=2`, HistGradientBoosting `max\_iter=200`을 사용한다. 후속 final-loss L1 track 은 notebooks 에서 `solver=liblinear`, `penalty=l1`, `C=0.25`, `max\_iter=4000`, `class\_weight=balanced`로 고정했다. Feature 후보 수는 flow-only 84 개, counter 보강 90 개, game-length prior 보강 108 개, KMeans archetype interaction 보강 127 개까지 확인했으며, 최종 본문은 성능 상한보다 selected/non-zero feature 중심의 설명력을 우선한다. 한편 `lab/02`~`lab/08`, `lab/10`의 공통 helper 는 비교 편의상 `game\_duration\_sec`를 포함한 12-feature numeric pool 로 실행되므로, 해당 노트북 표는 종료 후 정보가 서렌 label 에 만드는 leakage 영향(예: `lab/10`에서 importance 2 위)을 보여주는 참고 자료로 해석한다. 본문 Table 4~6 의 공식 수치는 `game\_duration\_sec`를 제외한 `src/team2\_surrender/modeling.py`의 11-feature 계약으로 산출했다.

Split	Rows	Match groups	Positive rows	Positive ratio
Train	3,232	1,616	545	16.86%
Validation	808	404	141	17.45%
Test	1,010	505	184	18.22%

Table 4. `match\_id` 기준 train/validation/test 분할. 같은 경기의 양 팀 row 가 서로 다른 split 에 들어가지 않도록 했다.

평가 지표는 accuracy, precision, recall, F1, ROC-AUC, PR-AUC, confusion matrix 를 함께 사용했다. 특히 positive class 가 17.23%에 불과하므로, majority baseline 도 높은 accuracy 를 낼 수 있다. 따라서 본 보고서에서는 positive class 탐지 능력을 보는 F1, recall, PR-AUC 를 핵심 지표로 해석한다.

6. RESULTS

6.1 EDA: 15 분 격차와 서렌 패배

서렌 패배 row 는 15 분 시점에서 골드, 킬, CS, 평균 레벨, 타워, 드래곤, 시야 지표가 전반적으로 불리했다. 특히 서렌 패배 팀의 평균 `gold\_diff\_15`는 -3,550.9 인 반면 비서렌 row 평균은 739.1 로 나타났다. 이는 골드 차이가 단순 독립 원인이라는 뜻은 아니며, 킬-CS·포탑·오브젝트 손실이 누적된 종합 신호로 해석해야 한다.




Figure 3. 서렌 패배 row 와 비서렌 row 의 15 분 feature gap. 시각화를 위해 골드는 1,000 골드 단위, CS 는 10 CS 단위로 조정했다.




Figure 4. 15 분 골드 차이 구간별 서렌 패배 비율. 5,000 골드 이상 불리한 구간에서 서렌 패배 비율은 50.2%까지 상승한다.
Source: `data\_1` CSV 집계, $\leq -5,000$ 병합 구간 기준(`lab/02` 표는 -8,000 경계 세분 구간: $\leq -8,000$ 61.4%, $-8,000 \sim -5,000$ 46.4%).

6.2 Baseline performance for `team\_surrendered`

11 개 canonical feature 만 사용하고 `game\_duration\_sec`를 제외한 baseline 결과는 다음과 같다. Dummy 는 accuracy 0.818 을 기록했지만 실제 서렌 패배 184 건 중 0 건을 잡아 F1 이 0 이었다. Logistic Regression 은 recall 이 높지만 false positive 가 많고, Random Forest 는 보수적으로 예측해 precision 은 높지만 recall 이 낮았다.

Model	Accuracy	F1	Precision	Recall	ROC-AUC	PR-AUC
Dummy	0.818	0.000	0.000	0.000	0.500	0.182
Logistic Regression	0.726	0.494	0.372	0.734	0.810	0.494
Random Forest	0.834	0.408	0.580	0.315	0.785	0.477
HistGradientBoosting	0.815	0.305	0.482	0.223	0.745	0.386

Table 5. 11-feature `team\_surrendered` baseline 성능. Dummy 의 높은 accuracy 는 positive class 탐지를 의미하지 않는다.

Source: `src/team2\_surrender/modeling.py` + `data\_1` 실행 — 공식 11-feature 기준(`game\_duration\_sec` 제외).




Figure 5. 11-feature baseline metric comparison. Accuracy 와 positive class 탐지 성능이 서로 다르게 움직인다.

6.3 Threshold tuning and final surrender baseline

Validation 기준 threshold 를 조정한 뒤 hold-out test 에 적용하면, F1 균형 후보는 tuned Random Forest 가 가장 적절했다. 이 모델은 test F1 0.522, precision 0.438, recall 0.647 을 기록했다. Recall 중심 Logistic Regression 은 실제 서렌 패배를 조금 더 많이 잡지만 false positive 가 증가한다.

Track	Model	Threshold	Test F1	Precision	Recall	해석
F1 균형	Random Forest	0.50	0.522	0.438	0.647	최종 서렌 baseline
Recall 중심	Logistic Regression	0.55	0.509	0.414	0.663	위험 탐지 보조 후보
극단 Recall	Logistic Regression	0.30	0.419	0.270	0.935	오탐 과다
Precision 중심	Random Forest	0.60	0.503	0.511	0.495	오탐 감소, recall 하락

Table 6. Threshold tuning 결과와 운영 해석. Validation 에서 선택한 threshold 를 hold-out test 에 적용했다.
Source: 공식 11-feature threshold tuning 재현 기록 — `game\_duration\_sec` 제외, `src` 파이프라인 기준.




Figure 6. Threshold trade-off. 운영 목적에 따라 recall 중심 또는 precision 중심 후보를 다르게 선택할 수 있다.

6.4 Final-loss / Dead Game risk analysis

후속 실험의 핵심은 단순 성능 향상이 아니라 target 정의를 분리했다는 점이다. `team\_surrendered`는 패배와 서렌 행동이 결합된 noisy label 이다. 반면 `final\_loss`는 15 분 경기 상태가 최종 결과와 얼마나 연결되는지 보는 target 이며, 한 경기당 패배 팀 1 행만 positive 가 되므로 양성률이 50%이다. 따라서 두 target 의 F1 을 같은 조건의 직접 성능 비교로 과장하지 않고, label noise 차이를 보여주는 근거로 해석한다.

구분	Target	대표 모델	F1	PR-AUC	해석
초기 최종 후보	team_surrendered	tuned RF	0.522	0.497	서렌 행동 label 기준선
target reframing check	final_loss	L1 LR(lab/04-07)	0.764	0.830	target noise 차이 확인
compact 설명 후보	final_loss	10 selected-feature L1 LR	0.771	0.848	설명력 중심
interaction 후보	final_loss	L1 LR + archetype interactions	0.776	0.839	최종 위험 분석 후보

Table 7. 서로 다른 target 간 진단 요약 — 직접적인 모델 성능 비교가 아님. 서로 다른 target 의 F1 을 동일 조건 성능 향상으로 과장하지 않는다.

Source: 11-feature tuned RF baseline 기록 및 `lab/04`·`lab/07`·`lab/09`·`lab/14` 출력 대조.




Figure 7. Problem reframing result. 15 분 상태는 서렌 행동 자체보다 최종 패배/Dead Game 위험을 더 안정적으로 설명한다.

Source: Table 7 compilation.

위 target reframing 표의 수치는 보고 기준이 서로 다르다. tuned RF 는 validation 기반 threshold/model selection 을 거쳐 hold-out test 에 적용한 11-feature 서렌 baseline 이고, reframing check 는 seed 42 단일 실험(`lab/04`·`lab/07`), compact 는 seeds 11-15 5-seed 평균(`lab/09`), interaction 은 seeds 11/42/77 3-seed 평균(`lab/14`)이다. 따라서 동일 조건의 직접 성능 비교가 아니라, target 과 feature pool 차이에 따른 설명력 차이를 보여주는 근거로 해석한다. 또한 Table 5 의 Random Forest 는 11-feature baseline 이고, Table 7 의 tuned RF 는 validation 기반 threshold/model selection 을 거친 서렌 baseline track 이므로 PR-AUC 수치를 같은 행의 반복 측정처럼 비교하지 않는다. 추가로 MLP 와 boosting 계열 모델도 성능 상한 확인용으로 비교했다(`lab/06`, `lab/11`, `lab/14`). final-loss 에서 MLP 는 F1 0.7765 로 L1 LR(0.7640)과 비슷했고, XGBoost/LightGBM 은 PR-AUC 에서 강점이 있었지만, 본 프로젝트의 최종 목적은 최고 성능보다 설명 가능성이므로 coefficient 와 scorecard 해석이 가능한 L1 Logistic Regression 을 중심으로 정리했다.




Figure 8. Compact L1 Logistic Regression 의 10 selected/non-zero feature 계수. 방향성은 feature 간 상관과 정규화의 영향을 받으므로 인과 효과로 해석하지 않는다.
Source: `lab/09` coefficient 출력.




Figure 9. Compact L1 risk decile. 예측 위험 decile 이 올라갈수록 실제 final_loss positive rate 도 함께 증가하여 위험 점수의 정렬력이 확인된다.
Source: `lab/09`·`lab/12` decile 출력.

또한 `lab/13\_seungbeom\_data3\_lolalytics\_final\_loss.ipynb`에서는 외부 champion context 를 명시적으로 feature pool 에 결합했다. Counter pick prior 는 Lolalytics 16.9 의 champion-position 별 top counter 승률을 이용해 `counter\_strength\_diff`와 `counter\_vulnerability\_diff`로 집계했고, champion game-length prior 는 15-20, 20-25, 25-30, 30-35, 35-40, 40+ 구간의 champion-position 승률 profile 을 팀 평균과 상대팀 대비 차이로 변환했다. 이 과정에서 feature 후보는 flow-only 84 개에서 counter 보강 90 개, counter+game-length 보강 108 개로 늘어났다.




Figure 10. Lab 13 의 Lolalytics context 결합 결과. Counter pick prior 는 후보 feature 를 84 개에서 90 개로, champion game-length prior 는 108 개로 확장했다.

성능 표에서도 `flow\_counter\_game\_length / lr\_l1` 후보는 test F1 0.7792, recall 0.8594, PR-AUC 0.8416 을 기록했다. 다만 이 prior 는 현재 match 의 실제 종료 시간이나 종료 bucket 을 사용하지 않고, 경기 시작 전 알 수 있는 champion-position 조합의 외부 승률 profile 만 사용한다. 따라서 leakage 방어 관점에서는 `game\_duration\_sec`와 다르며, 해석 관점에서는 주 feature 가 아니라 조합 맥락을 보강하는 보조 prior 로 두는 것이 적절하다.




Figure 11. Lab 14 의 interaction-feature L1 scorecard. 최종 후보의 selected coefficients 안에 `team\_game\_length\_wr\_35-40\_diff`와 `team\_game\_length\_wr\_15-20\_diff`가 포함되어, champion game-length prior 가 보조 설명 변수로 실제 선택되었음을 보여준다.

정리하면 counter pick 과 game-length 기반 champion 승률 feature 는 모두 실험했다. 다만 `lab/13`의 판단처럼 외부 champion context 는 gold, kill, dragon, level 같은 15 분 flow feature 를 대체하는 핵심 신호라기보다, 같은 15 분 상태라도 조합의 early/late 성향과 matchup 취약성이 다른 점을 설명하는 보조 맥락으로 제한해서 해석한다. 이 제한 덕분에 보고서는 외부 데이터를 과장하지 않으면서도 실제로 시도한 feature engineering 범위를 더 분명하게 보여준다.

6.5 추가 검증: 외부 prior 기여, 모델 패밀리, seed 안정성

본 절은 저장소 노트북 실행 output 에서 그대로 인용 가능한 세 가지 보강 근거를 정리한다. 외부 prior 의 단계별 기여는 `lab/13`, 더 복잡한 모델 패밀리와의 비교는 `lab/14`, 다중 seed 안정성은 `lab/08`의 출력 기준이다.

Feature pool	Features	Model	Test F1	Recall	PR-AUC
flow_only	84	hgb	0.7684	0.8277	0.8714
flow_only	84	lr_l1	0.7592	0.7960	0.8249
flow_only	84	lr_l2	0.7559	0.7881	0.8227
flow_counter	90	lr_l2	0.7678	0.8218	0.8305
flow_counter	90	lr_l1	0.7672	0.8158	0.8316
flow_counter	90	hgb	0.7593	0.7901	0.8706
flow_counter_game_length	108	lr_l1	0.7792	0.8594	0.8416
flow_counter_game_length	108	lr_l2	0.7763	0.8317	0.8401
flow_counter_game_length	108	hgb	0.7689	0.7941	0.8803

Table 8. 외부 champion prior 단계별 기여(`lab/13`, data_3 final_loss, test 기준). counter prior 단독 기여는 제한적이며, game-length prior 까지 결합하면 L1 LR 의 recall 이 0.796 에서 0.859 로 상승한다.

Model	F1	Precision	Recall	PR-AUC	ROC-AUC
lr_l1	0.7756	0.7041	0.8634	0.8394	0.8447
lr_l2	0.7735	0.7137	0.8449	0.8383	0.8439
rf	0.7676	0.6777	0.8851	0.8486	0.8423
lgbm	0.7659	0.7193	0.8198	0.8642	0.8558
xgb	0.7653	0.7349	0.7987	0.8662	0.8579
hgb	0.7590	0.7463	0.7723	0.8640	0.8555

Table 9. Archetype interaction pool(127 features)에서의 모델 패밀리 비교(`lab/14`, seeds 11/42/77 평균). boosting 계열은 PR-AUC 가 높지만 F1 격차는 0.02 이내이므로, 계수 해석이 가능한 L1 LR 을 최종 후보로 유지한다.

통계량	F1	Precision	Recall	PR-AUC	ROC-AUC
mean	0.7661	0.7084	0.8352	0.8399	0.8416
std	0.0120	0.0195	0.0312	0.0189	0.0160
min	0.7434	0.6887	0.7861	0.8153	0.8254
max	0.7894	0.7399	0.8752	0.8836	0.8801

Table 10. final-loss L1 LR 의 10-seed(10-19) 안정성(`lab/08`, `game\_duration\_sec` 포함 12-feature helper pool). F1 표준편차 0.012 로 단일 split 우연이 아니며, Table 7 의 compact track 평균(0.771)과 같은 수준이다. 공식 11-feature 결과가 아닌 leakage 점검용 진단(helper) 실행이다.

Table 10 의 seed 반복에서 핵심 10 개 feature 의 계수 부호 일관성은 모두 1.0 이었고, `ward\_kill\_diff\_15`만 9/10 seed 에서 선택되었다. 반면 `game\_duration\_sec`는 7/10 seed 에서만 선택되고 평균 계수 0.008 로 사실상 0 이었다. 즉 final_loss target 에서는 종료 후 metadata 가 입력에 남아 있어도 L1 이 이를 신호로 쓰지 않으며, 15 분 flow feature 가 위험 설명의 실질 신호라는 본문 해석과 일치한다.

7. ANALYSIS / DISCUSSION

7.1 기획 해석: 게임 길이 단축보다 “끝났다고 느끼는 시간” 축소

본 프로젝트의 산업적 해석은 “게임을 무조건 짧게 만들자”가 아니다. 핵심은 유저가 이미 끝났다고 느끼는 게임의 잔여 체감 시간을 줄이고, 불리한 팀이 다시 플레이할 이유를 느끼도록 만드는 것이다. Swiftplay, Objective Bounties, respawning Nexus Turrets 는 각각 빠른 SR 경험, 불리한 팀의 comeback 목표, 절망적 수비 상황 완화라는 디자인 방향을 보여준다. 본 모델은 이러한 패치 방향을 데이터 관점에서 설명하는 early warning 분석 도구로 사용할 수 있다.

7.2 왜 서렌 label 은 어렵고 final_loss 는 더 안정적인가

`team\_surrendered`는 “졌고, 그 패배가 일반 서렌으로 끝났는가”를 뜻한다. 같은 15 분 상태라도 어떤 팀은 끝까지 플레이하고 어떤 팀은 서렌을 선택할 수 있다. 팀 내부 갈등, 채팅, 조합 scaling, 15 분 이후 한타, 플레이어 성향은 현재 feature 로 관측되지 않는다. 그래서 F1 0.52 대는 feature 가 무의미하다는 뜻이 아니라, 서렌 선택 label 자체가 행동 noise 를 많이 포함한다는 뜻이다.

`final\_loss`는 15 분 상태와 더 직접적으로 연결된다. 골드, 레벨, 드래곤, 타워, 킬, CS 차이는 실제 최종 패배 위험을 안정적으로 정렬한다. 단, final-loss 성능 상승은 target, dataset, feature set 이 함께 바뀐 결과이므로 “모델만 바뀌 성능이 올랐다”고 해석하면 안 된다. 보고서의 최종 주장은 “서렌 추천기”가 아니라 “15 분 상태 기반 Dead Game 위험 설명 모델”이다.

7.3 오분류 해석: 모델이 틀리는 지점

최종 서렌 baseline 인 F1 균형 Random Forest 는 test set 의 실제 서렌 패배 184 건 중 약 119 건을 포착했고, 약 65 건은 false negative 로 남겼다. 이 false negative 는 15 분 시점의 골드·레벨·오브젝트 격차가 아직 극단적이지 않았지만 15 분 이후 한타 패배, 연속 오브젝트 손실, 조합 scaling 실패, 팀 내부 의사결정 변화로 급격히 무너진 경기로 해석할 수 있다. 즉 FN 은 모델이 약하다는 증거만이 아니라, 15 분 이후 정보가 실제 서렌 행동에 얼마나 크게 작용하는지를 보여주는 사례이다.

반대로 false positive 는 약 153 건으로 계산된다. 이는 모델이 서렌 위험으로 판단했지만 실제로는 일반 서렌 패배로 끝나지 않은 row 이다. 이 경우 15 분 상태는 불리했으나 이후 역전했거나, 불리한 상태에서도 팀이 끝까지 플레이한 경기일 수 있다. 따라서 FP 는 단순한 오탐이르기보다 “위험 신호는 있었지만 실제 서렌 행동으로 이어지지 않은 경기”로 보는 편이 더 적절하다. 실제 사례를 보면 이 해석이 구체화된다. Table 6 프로토콜을 재현한 실행(동일 group split, 기록된 하이퍼파라미터)의 test set 에서, 한 FN 사례는 15 분에 골드 +5,241·킬 +9·포탑 +1·드래곤 +1 로 오히려 우세해 재현 위험도가 0.01 이었지만 약 29 분에 일반 서렌 패배로 끝났고, 다른 FN 사례는 골드 +3,514 우세에서 약 38 분 장기전 끝에 서렌 패배했다. 반대로 한 FP 사례는 15 분에 골드 -11,901·킬 -14·포탑 -4 의 큰 열세로 위험도 0.94 였지만 일반 서렌 패배 없이 약 19 분에 종료되었다. match 식별자는 표기하지 않으며, 세 사례 모두 15 분 이후 정보가 서렌 행동을 좌우한다는 본 절의 해석을 실측으로 뒷받침한다.

이 오분류 구조는 본 프로젝트의 결론과 연결된다. `team\_surrendered`는 경기 상태와 유저 의사결정이 결합된 행동 label 이므로, 15 분 feature 만으로 완전히 설명하기 어렵다. 반면 `final\_loss`는 15 분 상태와 더 직접적으로 연결되기 때문에 risk decile 이 실제 positive rate 를 안정적으로 정렬한다. 결국 모델의 역할은 개별 경기의 서렌 여부를 단정하는 것이 아니라, 15 분 상태가 만든 위험군을 설명하고 어떤 유형의 불리함이 회복되거나 무너지는지 분석하는 것이다.

7.4 취약점과 방어 논리

취약점	해석 및 대응
F1/precision 부족	서렌 행동 label 은 noisy 하므로 개별 경기 판정기가 아니라 위험 신호 탐지 baseline 으로 해석한다.
game_duration_sec 누수 가능성	최종 보고서에서는 `game_duration_sec`를 metadata 로만 두고 15 분-only feature 에서 제외한다.
effective feature 수 혼동	정의 feature 는 11 개, 이번 run 의 all-zero 전령을 제외한 실질 신호는 10 개 수준으로 구분한다.
인과관계 한계	관찰 데이터 기반 예측이므로 골드/오브젝트 차이가 서렌을 직접 유발한다고 단정하지 않는다.
단일 서버/패치 편향	KR 서버 및 특정 수집 조건의 결과이므로 패치·티어·챔피언별 후속 분석이 필요하다.
game_length prior 처리	`game_length` prior 는 현재 경기의 실제 종료 시간이 아니라 champion-position 별 시간대 승률 사전 분포이며, match 고유 결과가 아닌 15 분 이전 champion-position 정보로 join 된다.

Table 11. 주요 취약점과 방어 논리. 성능 수치보다 label noise, leakage, 해석 범위를 명확히 하는 데 초점을 둔다.

7.5 윤리, 공정성, 적용 한계

본 분석은 개별 유저를 평가하거나 특정 팀에게 서렌을 권고하기 위한 도구가 아니다. 입력은 팀 단위 집계 feature 이며, 공개 산출물에는 개인 식별자와 계정 정보를 넣지 않았다. 따라서 모델 출력은 “누가 못했는가”가 아니라 “어떤 15 분 상태가 패배 위험과 함께 관측되는가”를 설명하는 aggregate signal 로만 해석해야 한다.

공정성 측면에서는 KR 서버, 특정 수집 시기, 랭크 솔로/듀오, v16.9 외부 prior 라는 범위 제한이 있다. 티어, 패치, 챔피언 메타가 바뀌면 같은 feature 의 의미와 threshold 도 달라질 수 있으므로, 실제 서비스 적용 전에는 패치별 재학습, 티어별 calibration, champion/role subgroup 점검이 필요하다. 특히 서렌 추천 자동화는 플레이 경험을 왜곡하거나 포기 행동을 강화할 수 있으므로, 본 결과는 패치 방향과 역전 장치 설계를 논의하는 보조 근거로만 사용한다.

7.6 향후 확장 방향

첫째, patch 와 티어별 일반화 검증이 필요하다. 본 보고서는 KR 서버 랭크 솔로/듀오와 v16.9 보강 데이터를 중심으로 해석했지만, champion balance 와 objective value 는 patch 마다 변한다. 따라서 실제 적용을 고려한다면 patch 별 재학습, 티어별 calibration, champion/role subgroup 별 성능 점검을 분리해서 수행해야 한다.

둘째, 상단 오브젝트 feature 정의를 현재 패치 구조에 맞게 갱신할 필요가 있다. 이번 run 에서 `rift\_herald\_diff\_15`는 all-zero 로 관측되었고, raw timeline 에서는 15 분 이전 상단 오브젝트가 `HORDE` 이벤트로 기록되는 흐름이 확인되었다(약 2,600 경기 raw 스캔 기준 15 분 이전 `HORDE` 7,626 건 `DRAGON` 3,822 건이 기록되었고 `RIFTERALD` 2,304 건은 모두 15 분 이후였다. raw JSON 은 용량 정책상 저장소에 포함하지 않는다). 후속 실험에서는 `horde\_diff\_15` 또는 voidgrub 관련 feature 를 별도로 만들고, 기존 전령 feature 는 15 분 기준 모델에서 제외하거나 20 분 기준 분석으로 이동하는 것이 더 자연스럽다.

셋째, 15 분 이후 comeback event 를 별도 분석해야 한다. 현재 모델이 FP 로 표시한 경기는 “불리했지만 버틴 경기”이고, FN 으로 놓친 경기는 “겉으로는 괜찮았지만 이후 무너진 경기”일 가능성이 있다. 두 집단을 15~25 분 구간의 dragon, Baron, turret, shutdown, teamfight event 와 연결하면, 단순 예측 성능보다 게임 길이 단축·포기감 완화·역전 장치 설계에 더 직접적인 근거를 제공할 수 있다.

8. CONCLUSION

본 프로젝트는 Riot API 기반 랭크 솔로/듀오 데이터를 이용해 15 분 팀 단위 feature 가 일반 서렌 패배와 최종 패배 위험을 얼마나 설명하는지 분석했다. 데이터 계약 기준 canonical feature 는 11 개이며, `game\_duration\_sec`는 feature 가 아니라 metadata 로 제외했다. 이를 반영해 최종 보고서는 11-feature 서렌 baseline, selected-feature compact L1 final-loss 설명 모델, 그리고 Dead Game 위험 해석으로 구조화했다.

초기 `team\_surrendered` 실험에서는 tuned Random Forest 가 test F1 0.522, recall 0.647, precision 0.438 을 기록했다. 이는 15 분 상태가 서렌 패배 흐름을 일정 수준 감지할 수 있음을 보여주지만, 서렌 선택 자체를 고성능으로 예측하기에는 한계가 있음을 동시에 보여준다. 반면 `final\_loss`로 target 을 분리하면 15 분 상태와 최종 결과의 연결이 훨씬 안정적으로 나타나며, compact L1 과 interaction L1 계열은 F1 0.77~0.78, PR-AUC 0.84~0.85 수준의 설명력을 보였다.

따라서 본 프로젝트의 최종 의의는 유저에게 서렌을 권고하는 것이 아니라, 15 분 시점의 어떤 경기 상태가 Dead Game 위험으로 이어지는지 설명하고, 게임 길이 단축·포기감 완화·역전 장치 설계 같은 패치 방향을 데이터 기반으로 논의하는 데 있다. 요약하면, 본 프로젝트는 서렌 여부를 단정하는 예측기가 아니라 15 분 시점의 불리함이 최종 패배 위험으로 정렬되는 구조를 설명하는 Dead Game risk analysis 로 해석되어야 한다.

9. PRESENTATION Q&A

본 절은 발표 후 실제 받은 질문 4 개와 추가 예상 질문을 최종 보고서 프레이밍에 맞추어 정리한 것이다. 핵심 답변 기준은 “15 분에 서렌을 추천하는 모델”이 아니라, “15 분 경기 상태가 final-loss/Dead Game 위험을 설명하고 실제 서렌 행동에는 추가적인 유저 의사결정 요인이 섞인다”는 점이다.

9.1 발표 후 실제 받은 질문

Q1. `lab/14`에서 feature 순위 1, 2 위가 m7 이면 7 분에 승패가 결정된다고 봐야 하는가?

사실관계는 맞다. `lab/14` scorecard 에서 `death\_diff\_cum\_m7`, `kill\_bounty\_diff\_cum\_m7` 처럼 7 분 시점 누적 지표가 상위에 올라왔다. 다만 feature ranking 은 예측 기여도나 상관 신호를 보여주는 것이지, 그 시점에 결과가 인과적으로 확정되었다는 뜻은 아니다.

근거는 세 가지이다. 첫째, m7 feature 를 사용하지 않는 compact 모델(`lab/09`)도 F1 0.7711, PR-AUC 0.8478 수준을 유지했고, m7 과 변화량을 포함한 interaction 모델(`lab/14`)은 F1 0.7756, PR-AUC 0.8394 였다. 두 실험은 완전한 동일 조건 ablation 은 아니므로 과장하면 안 되지만, 성능이 7 분 정보에만 전적으로 의존한다고 보기는 어렵다. 둘째, L1 Logistic Regression 은 상관성이 높은 feature 들 중 일부에 계수를 집중시키는 경향이 있으므로, 계수 순위를 곧바로 “승패 결정 시점”으로 읽는 것은 위험하다. 셋째, 같은 scorecard 에서 `gold\_diff\_delta\_7\_15` 같은 7 분→15 분 변화량 feature 도 상위에 남아 있어 7 분 이후 흐름 역시 설명 신호로 작동한다.

따라서 발표 답변은 “7 분 feature 가 높게 나온 것은 초반 손실이 강한 선형 신호라는 뜻이지, 7 분에 승패가 확정된다는 뜻은 아니다. 저희 주장은 15 분에 승패가 결정된다는 것이 아니라, 15 분까지 관측 가능한 정보로 최종 패배 위험을 설명한다는 것이다. 더 엄밀한 비교는 후속으로 `m7 only`, `m15 only`, `m7+m15`, `m7+delta\_7\_15`를 같은 split 에서 비교해야 한다”로 정리한다.

Q2. negative class 에 승리 팀과 비서렌 패배 팀이 같이 있는데, 모델이 배운 것이 서렌 의사인지 패배 가능성인지 어떻게 구분하는가?

현재 `team\_surrendered` label 만으로는 순수한 서렌 의사와 패배 가능성을 완전히 분리할 수 없다. 초기 label 에서 positive 는 “서렌으로 패배한 팀”이고, negative 에는 “승리 팀”과 “서렌하지 않고 패배한 팀”이 함께 들어간다. 따라서 초기 모델은 순수한 심리적 서렌 의사 모델이라기보다, 15 분 경기 상태가 서렌 패배와 얼마나 연결되는지 확인하는 baseline 에 가깝다.

이를 확인하기 위해 같은 feature 와 같은 모델 계열에서 target 만 바꾼 audit 을 수행했다. `team\_surrendered`는 F1 0.5688, PR-AUC 0.5792 였고, `final\_loss`는 F1 0.7640, PR-AUC 0.8296 이었다(`lab/07`). 이 수치는 Table 7 의 tuned RF 서렌 baseline(F1 0.522, PR-AUC 0.497)과 목적이 다르다. 전자는 target 만 바꿔 본 label audit 이고, 후자는 validation 기반 threshold tuning 까지 거친 최종 서렌 baseline 이다. 따라서 두 숫자는 같은 실험의 반복 측정이 아니라 서로 다른 목적의 진단값이다.

최종 주장은 “서렌 의사 예측”이 아니라 “15 분 상태 기반 final-loss/Dead Game 위험 설명”으로 좁힌다. 더 엄밀한 후속 연구는 패배 팀만 대상으로 `서렌 패배 vs 비서렌 패배`를 비교하거나, 1 단계로 `final\_loss`를 예측한 뒤 2 단계에서 패배 조건부 서렌 여부를 예측하는 two-stage model 로 설계하는 것이 맞다.

Q3. 주요 feature 가 골드, 킬, CS, 타워 차이처럼 승패와 직접 연결된 지표인데 새로운 인사이트는 무엇인가?

주요 feature 가 승패와 직접 연결된 지표라는 지적은 맞다. 따라서 본 프로젝트가 “숨은 새로운 승패 원인”을 발견했다고 주장하면 과장이다. 핵심 인사이트는 특정 feature 하나가 아니라, 15 분 경기 상태 신호를 `team\_surrendered` 행동 label 과 `final\_loss` 결과 label 로 분리해 보았다는 점이다.

같은 15 분 feature 라도 `team\_surrendered`는 상대적으로 설명하기 어려웠고, `final\_loss`는 훨씬 안정적으로 설명되었다. 이는 실제 서렌 행동에는 경기 상태 외에도 플레이어 성향, 팀 분위기, 15 분 이후 한타, 조합 scaling 같은 관측되지 않은 요인이 섞인다는 뜻이다. EDA 에서도 서렌 패배 팀은 `gold\_diff\_15`, `cs\_diff\_15`, `kill\_diff\_15`, `tower\_diff\_15`, `dragon\_diff\_15`, `avg\_level\_diff\_15`가 함께 낮아지는 누적 열세 패턴을 보였다.

Risk decile 결과는 held-out calibration 이라고 표현하기보다 설명용 risk segmentation 또는 위험 점수 정렬력 확인으로 표현하는 것이 안전하다. 낮은 위험 구간의 실제 패배율은 약 3.8%, 높은 위험 구간은 약 96.2%로 갈랐다(interaction 모델 `lab/14`의 decile 기준이며, Figure 9 의 compact decile 은 5.9%~94.1%이다). 골드 구간 수치는 binning 정의를 함께 말해야 한다. Figure 4 의 50.2%는 `gold\_diff\_15 ≤ -5,000` 병합 구간 기준이고, `lab/02` 세분 bucket 에서는 `≤ -8,000` 구간이 61.4%, `-8,000~-5,000` 구간이 46.4%이다.

Q4. 전처리를 scikit-learn pipeline 으로 고정한 이유는 무엇인가?

scikit-learn `Pipeline`과 `ColumnTransformer`를 사용한 이유는 재현성, 데이터 누수 방지, 모델 간 공정 비교 때문이다. imputation 이나 scaling 은 train set 에서만 fit 하고 validation/test 에는 transform 만 적용해야 한다. 이를 수동으로 처리하면 전체 데이터 기준으로 전처리하는 leakage 가 발생할 수 있다.

Logistic Regression 은 coefficient 크기와 규제가 feature scale 에 영향을 받기 때문에 median imputation 과 `StandardScaler`를 적용했고, Random Forest 나 HistGradientBoosting 같은 tree 계열은 scale 변환에 덜 민감하므로 imputation 중심으로 처리했다. 특히 threshold 와 모델 선택은 validation 에서 하고, hold-out test 는 마지막 평가에 한 번만 사용했기 때문에 전처리뿐 아니라 모델 선택 단계에서도 test leakage 를 줄이려 했다.

따라서 Pipeline 은 특정 전처리 방법을 고정한다는 뜻이 아니라, 전처리와 모델을 하나의 검증 가능한 객체로 묶어 leakage 없이 비교하기 위한 장치이다. XGBoost, LightGBM, MLP 도 성능 상한 확인용으로 비교했지만, 최종 설명 모델은 coefficient 와 scorecard 해석이 가능한 L1 Logistic Regression 중심으로 정리했다.

9.2 해당 프로젝트에 대한 Team 2 가 들었던 의문

Q5. 최종 목표는 서렌 예측인가, 승패 예측인가?

초기 목표는 `team\_surrendered` 예측이었다. 그러나 실험 결과 서렌 label 은 행동 요인이 많이 섞인 noisy label 이었다. 따라서 최종 목표는 서렌 추천 모델이 아니라, 15 분 경기 상태가 `final\_loss` / Dead Game 위험을 얼마나 설명하는지 분석하는 모델로 정리했다.

Q6. 왜 15 분을 기준으로 삼았는가?

15 분은 LoL 에서 일반 서렌 투표가 가능해지는 시점과 연결된다. 또한 라인전, 오브젝트, 성장 차이가 어느 정도 누적되어 팀 단위 상태 비교가 가능한 시점이다. 단, 본 보고서의 주장은 “15 분에 승패가 확정된다”가 아니라 “15 분까지의 관측 정보가 최종 패배 위험을 설명한다”이다.

Q7. 데이터 단위와 leakage 방지는 어떻게 설계했는가?

한 행은 participant 가 아니라 match-team row 이다. 한 경기에서 블루 팀과 레드 팀 두 행을 만들고, feature 는 “우리 팀 값 - 상대 팀 값” 형태의 차이값으로 구성했다. 같은 경기의 두 팀 row 가 train/test 에 갈라지면 상대 정보가 동시에 들어가는 leakage 가 생기므로 `match\_id` 기준 group split 을 사용했다. feature 는 15 분 frame 또는 15 분 이전 event 만 사용했고, 최종 승패, 서렌 플래그, 15 분 이후 event 는 입력 feature 에서 제외했다.

Q8. 왜 accuracy 를 주요 지표로 쓰지 않았고, final_loss F1 0.77 은 의미 있는가?

`team\_surrendered` positive 비율은 약 17.23%라 모두 negative 로 예측해도 accuracy 가 높게 나올 수 있다. 그래서 F1, recall, precision, PR-AUC 를 함께 보았다. `final\_loss`는 양성률이 50%라 전부 positive 로 찍어도 F1 이 약 0.667 까지 나올 수 있으므로 F1 만 보면 부족하다. 따라서 PR-AUC 와 ROC-AUC 를 함께 보았고, PR-AUC 0.83~0.85 수준은 무작위 기준선 0.5 보다 의미 있는 설명력으로 해석했다.

Q9. 왜 XGBoost 나 딥러닝을 최종 모델로 쓰지 않았는가?

성능 상한 확인용으로 XGBoost, LightGBM, MLP 를 비교했다. PR-AUC 에서는 boosting 계열이 더 높게 나온 경우도 있었지만, F1 격차는 제한적이었고 L1 Logistic Regression 은 coefficient 와 scorecard 로 해석하기 쉽다. 본 프로젝트는 최고 점수 경쟁보다 “15 분 상태가 어떤 방식으로 위험을 설명하는가”가 중요하므로 L1 LR 을 최종 설명 모델로 유지했다.

Q10. Lolalytics game-length feature 는 실제 경기 시간 누수 아닌가?

아니다. 해당 feature 는 현재 match 의 실제 종료 시간이 아니라, champion-position 별 외부 통계에서 나온 시간대별 평균 승률 prior 이다. 즉 경기 후 정보를 넣은 것이 아니라, 경기 시작 전에도 알 수 있는 champion-position context 를 사용한 것이다. 다만 이 prior 는 gold, kill, dragon, level 같은 15 분 flow feature 를 대체하는 핵심 신호가 아니라 조합 맥락을 보강하는 보조 feature 로 제한해서 해석한다.

Q11. `rift\_herald\_diff\_15`가 all-zero 면 feature contract 가 잘못된 것 아닌가?

이번 run 에서는 데이터 품질 이슈를 발견한 것으로 정리하는 것이 맞다. 현 패치 구조에서 15 분 이전 상단 오브젝트가 `RIFTERALD`가 아니라 `HORDE`로 기록되는 흐름이 확인되었다. 기존 feature 계약 유지를 위해 `rift\_herald\_diff\_15`를 남겼지만, 후속 작업에서는 `horde\_diff\_15` 또는 voidgrub 관련 feature 로 갱신하는 것이 더 적절하다.

Q12. 일반화와 인과관계는 어디까지 주장할 수 있는가?

현재 데이터는 KR 서버, 특정 수집 시기, 랭크 솔로/듀오, v16.9 외부 prior 라는 범위 제한이 있다. 따라서 전체 티어와 모든 패치에 일반화할 수 없고, 패치별 재학습과 티어별 calibration 이 필요하다. 또한 관찰 데이터 기반 분석이므로 인과관계가 아니라 상관 및 예측 가능성으로 해석해야 한다. “골드 차이가 서렌을 유발한다”가 아니라 “15 분 골드 차이가 final-loss 및 서렌 패배 위험과 연결된다”가 정확한 표현이다.

발표 마무리 문장은 다음처럼 통일한다. “본 프로젝트는 서렌 추천 모델이 아니라, 15 분 경기 상태가 최종 패배 위험을 어떻게 설명하는지 분석하고, 실제 서렌 행동에는 경기 상태 외의 유저 의사결정 요인이 섞인다는 점을 정량적으로 보인 프로젝트이다.”

References

- Team 2 project repository. README.md, docs/data_contract.md, src/team2_surrender/modeling.py, and lab/01-lab/14 notebooks. Accessed 2026-06-08.
- Riot Games Developer Portal. "Match-V5 API." <https://developer.riotgames.com/apis#match-v5>. Accessed 2026-06-08.
- Lolalytics. "League of Legends champion statistics: counter and game-length aggregates, patch 16.9." <https://lolalytics.com/>. Accessed 2026-06-08.
- V. Hodge, S. Devlin, N. Sephton, F. Block, A. Drachen, and P. Cowling. "Win Prediction in Esports: Mixed-Rank Match Prediction in Multi-player Online Battle Arena Games." arXiv:1711.06498, 2017. <https://arxiv.org/abs/1711.06498>.
- T. D. Do, S. I. Wang, D. S. Yu, M. G. McMillian, and R. P. McMahan. "Using Machine Learning to Predict Game Outcomes Based on Player-Champion Experience in League of Legends." FDG 2021 / arXiv:2108.02799. <https://arxiv.org/abs/2108.02799>.
- J. B. S. Junior and C. E. C. Campelo. "League of Legends: Real-Time Result Prediction." arXiv:2309.02449, 2023. <https://arxiv.org/abs/2309.02449>.
- M. Wilathgamuwa. "Kills or Turrets: An Exploratory Data Analysis and Win Prediction of League of Legends Based on Early-Game Data." ICITR 2024, DOI: 10.1109/ICITR64794.2024.10857792.
- Riot Games. "/dev: Introducing Swiftplay." League of Legends, 2024-11-25. <https://www.leagueoflegends.com/en-sg/news/dev/dev-introducing-swiftplay/>.
- Riot Games. "Patch 11.23 Notes." League of Legends, 2021-11-16. <https://www.leagueoflegends.com/en-au/news/game-updates/patch-11-23-notes/>.
- Riot Games. "Patch 25.S1.1 Notes." League of Legends, 2025. <https://www.leagueoflegends.com/en-ph/news/game-updates/patch-25-s1-1-notes/>.
- F. Pedregosa et al. "Scikit-learn: Machine Learning in Python." Journal of Machine Learning Research, 12, 2825–2830, 2011.
- L. Breiman. "Random Forests." Machine Learning, 45, 5–32, 2001.
- R. Tibshirani. "Regression Shrinkage and Selection via the Lasso." Journal of the Royal Statistical Society: Series B, 58(1), 267–288, 1996.
- T. Chen and C. Guestrin. "XGBoost: A Scalable Tree Boosting System." KDD, 2016.
- G. Ke et al. "LightGBM: A Highly Efficient Gradient Boosting Decision Tree." NeurIPS, 2017.
- J. MacQueen. "Some methods for classification and analysis of multivariate observations." Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, 1967.
- T. Saito and M. Rehmsmeier. "The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets." PLOS ONE, 2015.