

1. Introduction

Abstract. 본 보고서는 2024~2025 년 NIA 디지털정보격차 실태조사 데이터를 결합해 개인의 디지털 적응수준을 3 단계로 분류하는 방법을 제안한다. 원천 데이터에는 개인 단위 정답 라벨이 없기 때문에, 본 프로젝트는 접근·역량·활용 관련 설문 문항 110 개와 AI 파생변수를 이용한 train-only K-means 군집화로 pseudo-label 을 설계했다. 이후 동일한 고정 분할과 118 개 공통 feature 위에서 MLP, LightGBM, SVM 을 비교했고, 단일 모델 기준 SVM 이 가장 높은 Test F1-macro(0.9927)를 기록했다. MLP 는 경계 샘플만 재분류하는 Two-Stage 구조를 추가하여 Test F1-macro 0.9935 까지 개선되었다. SHAP, LIME, permutation importance 를 이용한 해석 결과는 최근 인터넷 이용 시기(Q10), 파일 전송·콘텐츠 편집과 같은 기초활용 역량, 공공서비스 및 경제활동 관련 문항이 핵심 구분축임을 보여준다. 본 연구는 공식 조사 프레임워크인 개인 단위 예측 문제로 재구성하고, 취약계층의 디지털 적응을 설명 가능한 방식으로 단계화했다는 점에서 의의를 갖는다.

1.1. 문제 배경과 필요성



그라프1. 2025 디지털정보화 수준 개요

과학기술정보통신부·한국지능정보사회진흥원. 2025 디지털정보격차 실태조사 보고서. 2026.

공공서비스, 금융거래, 정보 탐색, 사회참여가 온라인 중심으로 재편되면서 디지털 격차는 더 이상 ‘기기를 보유했는가’만으로 설명되지 않는다. 한국지능정보사회진흥원의 2025년 공식 조사에서도 디지털정보화 수준은 접근(access), 역량(skill), 활용(usage)의 복합 지표로 정의되며, 같은 인터넷 이용자라도 실제 활용 능력과 서비스 경험의 격차가 크게 남아 있다. 특히 4 대 정보취약계층의 종합 디지털정보화 수준은 일반국민 대비 77.9%였고, 접근 수준은 96.6%로 상대적으로 높지만 역량 수준은 65.9%에 머물렀다. 고령층(71.8%)과 농어민(80.6%)은 종합 수준이 낮게 나타나, 단순 연결성보다 실제 적응 수준의 차이가

정책 문제로 남아 있음을 보여준다.

1.2. 해결하고자 하는 과제

그러나 공식 조사는 주로 집단 평균과 비율을 기술하는 데 초점을 둔다. 개인 단위 응답을 이용해 ‘이 사람이 어느 수준의 디지털 적응 단계에 속하는가’를 예측하는 라벨은 제공되지 않는다. 본 프로젝트는 이 빈틈을 개인 단위 예측 문제로 재구성한다. 즉, 설문 기반 디지털 활용 패턴을 바탕으로 적응 수준을 단계화하고, 이후 동일한 설문 응답만으로 그 단계를 재현하는 분류 모델을 구축하는 것이 핵심 과제다.

1.3. 프로젝트 목표 및 기여 요약

다섯 개 그룹(일반국민, 고령층, 장애인, 농어민, 저소득층)의 2024~2025 설문을 공통 변수 체계로 통합했다. train-only K-means 군집화를 통해 1 단계(완전 소외)·2 단계(부분 적응)·3 단계(자립 적응)의 pseudo-label 을 설계하고 외적 타당성을 검증했다. MLP, LightGBM, SVM 을 동일한 입력 체계 위에서 비교하고, SHAP·LIME·permutation importance 로 결과를 해석했다.

2. Related Work

2.1. 기존 연구 및 유사 접근 방식 조사

디지털 격차 연구는 지능정보사회에서의 역량, 활용, 지식 수준, 그리고 사회적 결과까지 포괄하는 다층적 개념으로 확장돼 왔다. 이기호(2019)는 지능정보사회에서 디지털 정보 격차가 기기 활용 능력과 사회적 참여의 문제로 이어진다는 점을 논의하였다. 이민상(2020)은 디지털 격차가 다시 지식격차로 연결될 수 있음을 지적하였다. 또한 정병호·주형근(2022)은 세대별 디지털 서비스 이용 차이를 통해 디지털 격차가 연령집단별로 상이한 양상과 구조를 가진다는 점을 보여주었다. 이러한 연구들은 디지털 격차를 접근(access), 역량(skill), 활용(usage), 그리고 결과(outcome)의 복합 구조로 이해해야 함을 시사한다.

최근 연구들은 디지털 격차의 양상이 사회 변화와 기술환경에 따라 동적으로 재편된다는 점에도 주목한다. 김현정·김범수·김미예(2024)는 코로나19 확산 시기를 중심으로 모바일 인터넷 이용량 증가와 디지털 격차의 관계를 분석함으로써, 격차가 단순히 고정된 상태가 아니라 사회적 충격과 기술 수용 환경 변화 속에서 달라질 수 있음을 보여주었다. 한편 과학기술정보통신부(2026)의 실태조사 결과 발표는 한국 사회에서 디지털 정보격차, 웹 접근성, 스마트폰 과의존이 여전히 중요한 정책 과제임을 보여주며, 공식 조사 체계 역시 디지털 적응 수준을 다면적으로 파악하고 있음을 확인시켜 준다. 즉, 최근의 정책 및 학술 연구는 공통적으로 디지털 격차를 “접근 여부”보다 더 넓은 적응과 활용의 문제로 바라보는 흐름을 보인다.

또한 디지털 전환이 인공지능 서비스 확산과 결합되면서, 디지털 격차는 AI 활용 격차와도 연결되고 있다. 김효주·홍석호·장은하(2026)는 노인의 디지털 정보화 수준이 인공지능 서비스 활용도에 미치는 영향을 분석하여, 디지털 역량이 높을수록 AI 서비스 접근과 활용 가능성도 커질 수 있음을 보여주었다. 이는 디지털 격차가 단순한 인터넷 사용 격차에 머무르지 않고, 새로운 지능정보 서비스 수용 능력 차이로 이어질 수 있음을 의미한다. 따라서 최근 관련 연구들은 디지털 격차를 고령층, 취약계층, 세대 간 차이뿐 아니라 AI 활용 맥락까지 확장해 해석하는 방향으로 발전하고 있다.

2.2. 기존 방법과 본 프로젝트의 차이점

기존 연구들의 중요한 공통점은 디지털 격차의 개념적 확장과 집단 수준 설명에 강점을 가진다는 점이다. 그러나 다수의 선행연구는 주로 특정 집단이나 시기, 혹은 특정 결과변수와의 관계를 중심으로 디지털 격차를 기술하거나 설명하는 데 초점을 두었다. 예를 들어 코로나19 시기의 모바일 인터넷 이용 변화, 노인의 AI 서비스 활용도, 세대별 서비스 격차, 혹은 지식 격차와의 관계는 모두 디지털 격차의 한 측면을 정교하게 조명하지만, 개인 단위 응답을 바탕으로 “디지털 적응 수준”을 하나의 예측 가능한 단계로 구조화하는 접근은 상대적으로 드물다.

본 프로젝트는 이러한 기존 연구와 달리, 공식 조사 데이터를 개인 단위 예측 문제로 재구성했다는 점에서 차별성을 갖는다. 첫째, NIA 디지털정보격차 실태조사 2024~2025 데이터를 통합하여, 라벨이 없는 상황에서 train-only K-means를 통해 digital_stage라는 3단계 pseudo-label을 설계하였다. 둘째, 접근·역량·활용 문항과 AI 파생변수를 함께 사용하여, 디지털 적응 수준을 복합적 역량과 활용 패턴의 결과로 모델링하였다. 셋째, 이후 MLP, LightGBM, SVM을 동일한 feature set 위에서 비교함으로써, 기존의 서술적·설명적 연구를 넘어 개인 수준 분류와 재현 가능성을 검증하였다. 넷째, SHAP, LIME, permutation importance를 통해 “무엇이 중요한가”뿐 아니라 “왜 특정 사람이 특정 단계로 분류되었는가”까지 설명함으로써, 설명가능한 머신러닝 기반 디지털 격차 분석으로 확장하였다.

요약하면, 기존 연구가 디지털 격차의 원인과 양상을 해석하는 데 강점을 가진다면, 본 프로젝트는 그 논의를 바탕으로 디지털 적응 수준을 단계화하고, 이를 예측하며, 다시 설명하는 체계를 제안했다는 점에서 차이가 있다. 즉, 선행연구가 디지털 격차를 사회현상으로 이해하는 토대를 제공했다면, 본 프로젝트는 그 토대를 개인 단위 데이터와 기계학습 모델로 연결해 실제 분류 가능한 분석 프레임으로 발전시켰다는 의의를 가진다.

3. Approach (or Method)

3.1. 전체 문제 해결 전략

본 프로젝트는 디지털 정보격차 실태조사 데이터를 기반으로 디지털 소외 계층의 특성을 다각도로 분석하고, 이를 바탕으로 실효성 있는 맞춤형 복지 정책을 제안하기 위해 원천 데이터 전처리에서 시작해 소외단계 정의, 소외단계로 분류하는 모델 구축, 이에 따른 결과를 설명 가능한 AI(XAI) 분석으로 마무리하는 체계적인 데이터 사이언스 파이프라인을 구축한다.

3.1.1. 원천 설문 데이터 기반 전처리

우선 2024년과 2025년의 한국지능정보사회진흥원 디지털정보격차 실태조사 데이터를 통합하여 분석의 신뢰성을 확보한다. 수집된 데이터는 결측값 처리, 범주형 변수 인코딩, 수치형 변수 스케일링 등 표준화된 전처리 과정을 거친다.

3.1.2. 비지도학습 기반의 소외 단계 정의

본 데이터셋은 디지털 소외 정도에 대한 사전 레이블(정답)이 존재하지 않으므로, 이를 해결하기 위해 비지도학습 알고리즘인 K-means 군집화를 도입한다. 실루엣 스코어와 엘보방식을 비교해 군집 갯수를 정한 후, 110개의 핵심 feature기반으로 지도 학습을 통해 3단계의 디지털 소외 계층 레이블을 정의한다.

3.1.3. 지도학습을 위한 분류 모델 구축

정의된 3단계 레이블을 기반으로 대규모 데이터 처리에 우수한 LightGBM, 정교한 결정 경계 형성에 강점이 있는 SVM, 복잡한 패턴 학습에 유리한 머신러닝 MLP 모델을 구축하여 성능을 비교 분석한다. 특히 SVM과 MLP 모델은 추가적인 하이퍼파라미터 최적화 및 고도화 과정을 거쳐 모델 예측력을 극대화할 방침이다. 모델 학습에는 공통된 평가 지표와 feature를 이용한다. 평가지표 측면에서는 데이터 분포에 따른 단순 Accuracy Score의 한계를 보완하고 데이터 불균형에 따른 왜곡을 방지하기 위해, 모든 클래스의 성능을 균등하게 반영하는 F1 Macro와 데이터별 빈도를 고려한 F1 Weighted 및 혼동행렬(Confusion Matrix)을 공통적인 핵심 지표로 활용함으로써 모델의 분류 안정성과 신뢰성을 확보한다.

3.1.4. 설명 가능한 AI(XAI) 기반의 원인 분석 및 정책 연계

최종 단계에서는 단순히 계층을 분류하는 예측 모델에 그치지 않고, 설명 가능한 AI(XAI) 기법 LIME을 적용하여 모델의 판단 근거를 투명하게 시각화하고 해석한다. 이를 통해 동일한 소외 계층 내에서도 기기 접근성 부족, 활용 교육 부재, 온라인 환경에 대한 심리적 불안 등 개인과 집단별로 소외를 유발하는 핵심 독립 변수가 무엇인지 구체적으로 규명한다.

3.2. 데이터 전처리

원천 자료는 한국지능정보사회진흥원(NIA)의 디지털정보격차 실태조사 2024년, 2025년 응답 자료다. 원천 파일은 연도별 조사 결과와 조사 대상 집단별 엑셀 파일로 구성되어 있으며, 최종 분석 범위에는 일반국민, 고령층, 장애인, 농어민, 저소득층의 다섯 집단을 포함했다. 북한 이탈주민과 결혼 이민자는 연령과 성별 외 공통 변수가 없어 다른 그룹과 동일 feature space 로 묶기 어려웠기에 전처리 목록에서 제외했다.

전처리 파이프라인은 다음과 같다.

3.2.1. 공백 및 문자열 정제

데이터 내 빈 셀이 공백 문자(' ')로 기록되어 있어, pandas가 결측치로 인지하지 못하는 오류를 방지하고자 전체 컬럼의 공백을 NaN으로 일괄 변환하였다.

3.2.2. 불필요한 컬럼 제거

1) 정보량 부족 및 데이터 결측 변수

- 주관식 및 텍스트: _ET 계열(100% 공백),

디지털 정보격차 기반 3단계 적용 수준 분류와 설명가능한 분석

ADQ8_1T(결측률 14.3%) 등 데이터 부재로 제거함.

- 100% 결측: 값이 전혀 존재하지 않는 데이터 부재 컬럼 일괄 삭제함.
- 상수형 데이터: Q2K1_1_1은 응답의 98%가 동일한 값으로 변별력이 없어 제외함.

2) 통계적 유의성이 낮은 극소수 응답 변수

- 미세 범주: 9997 포함 컬럼(선택자 1~43명), ADQ8A5~8(선택자 3~35명), Q2K1_1_2/3은 데이터 유의성이 부족하여 배제함.

3) 대체 가능 및 중복 변수

- 식별자 및 분류: 단순 식별자 응답ID와 그룹 코드 TYP(GROUP 컬럼으로 대체)를 삭제함.
- 중복 속성: ADQ3A(결측률 72.9%)는 표준 직업 변수(ADQ3)와 중복되어 제거함. Q4A_*(요금 금액) 계열은 모름 응답률이 높고 요금 부담 정도(Q4C)가 디지털 역량과 더 연관성이 높아 관련 플래그와 함께 삭제함.

4) 파생 변수 생성 및 통합 매핑에 따른 원본 변수

- AI 지표 원본: Q27A_*, Q27B_*, Q27C_*는 각각 하나의 통합 파생 변수(AI_인지, AI_사용빈도, AI_도움정도)로 가공 후 원본 열을 삭제함.
- 그룹 특화 변수: 그룹별 고유 문항 변수(BDQ_*, CDQ_*, DDQ_*)는 공통 변수 매핑 완료 후 교집합 결합(join='inner') 과정에서 제거함.

3.2.3. 특수 응답 처리

- 수치형 특수값 NA 치환: 일반 수치형 변수의 9998(모름/무응답), 9999(비해당) 등의 특수 코드가 대형 이상치(Outlier)로 작용해 모델 성능을 저하시키는 것을 방지하고자 결측치(NA)로 처리
- Flag 변수 NaN 임putation(0): Q27C_9998과 같이 컬럼명에 9998/9999를 포함하는 플래그형 변수의 결측치(NaN)는 미선택을 의미하므로 '0'으로 일괄 변환(Imputation)

3.2.4. 구조적 결측 처리(0 및 중앙값 대체)

- 대상: Q12 ~ Q19 계열 문항 (검색, 이메일, SNS, 생활서비스, 경제활동, 사회참여, 심화기술 이용 비율 등)
- 처리 배경 및 논리: 선행 문항에서 '인터넷 비이용자'로 분류된 응답자의 경우, 후속 질문인 이용 비율 문항이 원천적으로 제외되어 데이터상 결측치(NaN)로 기록됨. 그러나 이는 데이터 유실이 아닌 실질적인 이용률 "0%"를 의미하므로, 통계적 왜곡을 방지하기 위해 다음과 같이 분기 처리를 적용하여 구조적 결측치를 보정함.
- 세부 처리 방법:
 - 인터넷 이용 불가군 (Q3 = 2): 해당 그룹의 Q12 ~ Q19 결측치는 실제 서비스 이용률이 전무한 상태를 반영하여 모두 '0' 값으로 대체
 - 인터넷 이용 가능군 (Q3 = 1): 인터넷을 이용함에도 발생한 단순 무응답성 결측치는 데이터의 대푯값을 보존하기 위해 해당 변수의 중앙값으로 대체

3.2.5. Feature Engineering

기존의 단순 입력 값 및 그룹별로 파편화된 원본 데이터를 머신러닝 모델의 예측 성능 향상과 데이터 규격화를 위해 이진화, 도메인 스코어링, 표준 매핑 기법을 적용하여 피쳐 고도화를 수행하였다.

디지털 정보격차 기반 3단계 적용 수준 분류와 설명가능한 분석

• 이진화 Binarization

생성/변환 대상 피처	원본 데이터 정보	변환 방식 및 규칙	변환 이유
Q5K1_*	디지털 문제 발생 시 혼자 해결하는 방법 (포털/유튜브/앱 활용 등)	값 있음 = 1 NaN = 0	어떤 구체적인 해결 수단을 선호하는지가 모델 학습에 중요하므로 변수를 합산하지 않음
Q4B_1_1, Q4B_2_1	결합상품 가입 여부 (인터넷/모바일)	값 있음 = 1 NaN = 0	가입 상태(1)와 미가입 상태(0)를 명확히 구분
ADQ8A1 ~ 4	다인가구의 구체적인 구성원 유형	값 있음 = 1 NaN = 0	코드북 레이블이 "배우자"로 오기입된 오류를 배제하고, 유형별 독립 선택 여부 보존
Q28_*	AI 서비스를 미이용하는 원인 (7개 문항)	값 있음 = 1 NaN = 0	코드북 레이블이 동일 값으로 오작동된 오류를 보정하고, 미이용 사유 각각의 가중치를 독립적으로 학습
Q31_*	정보화 교육 수요 과정 (4개 문항)	값 있음 = 1 NaN = 0	교육 수요가 매칭되는 과정별 독립적 중요도를 반영하기 위해 합산 처리 배제
Q1_1, Q1_2, Q2K2_*, Q3	스마트패드 및 주변기기 보유 여부	보유 = 1 미보유 = 0	보유(1)와 미보유(0) 상태를 모델이 직관적으로 판단하도록 규격화

• 도메인별 점수 수치화 및 스코어링 (Scoring)

AI 서비스 관련 8개 카테고리 문항들을 분석하여, 통합 지표(Score Feature)들을 파생 변수로 생성하였다. (변수 생성 완료 후 원본 열은 차원 축소를 위해 일괄 제거함)

연계 원본 피처	신규 파생 변수명	세부 인코딩 및 연산 방식	변수 설계 의도 (해석 논리)
Q27A_*(8개 카테고리)	AI_인지	각 카테고리 인지 여부를 이진화 후 단순 합산 (수치 범위: 0 ~ 8)	인지하고 있는 AI 서비스 분야의 폭이 넓을수록 신기술 수용성 점수가 높다고 판단
Q27B_*(8개 카테고리)	AI_사용빈도	미인지는 미사용으로 간주(NaN = 0 처리)한 후 빈도 점수를 합산 (수치 범위: 0 ~ 32)	일상생활 속에서 AI 기술이 얼마나 깊이 있게 내 재화되어 자주 활용되는지 측정
Q27C_*(8개 카테고리)	AI_도움정도	전원 응답을 기반으로 도출된 도움 정도 척도 값을 합산 (수치 범위: 8 ~ 32)	AI 신기술에 대해 느끼는 긍정적인 심리적 효용감 및 태도 수준 지표화

• 데이터 표준화 및 도메인 결합 (Standardization & Join)

5개 조사 대상 파일별로 다르게 명명된 변수명을 표준 데이터 모델로 변환하고, 모델 피처로서 유효한 공통 분모 영역을 추출하는 통합 전처리를 수행하였다.

방법	실제 처리 내용	목적 및 이유
그룹별 공통 변수 통합 매핑	그룹별로 상이한 변수명(ADQ, BDQ, CDQ, DDQ 등)을 **연령, 성별, 직업, 학력, 가구구성형태, 가구소득, 거주지역**의 7대 표준 컬럼명으로 완전 일치화	다른 환경에서 수집된 5개 취약계층 그룹 파일을 단일 데이터셋 으로 합산할 때 동일 정보를 같은 피처로 정렬하기 위함
농어민 직업군 표준화	농어민 그룹의 직업 구분 변수(BDQ1)를 일반국민 직업 표준 코드 기준인 '6(농림어업 종사자)'으로 고정	서로 다른 세부 직업 분류 체계를 하나의 기준 코드로 통합하여 데이터 일관성 확보
공통 컬럼 교집합 추출 (join='inner')	5개 그룹을 병합할 때 전 그룹이 공유하는 공통 변수만 남기고 각 파일별 전용 컬럼 제거	특정 취약계층 그룹에만 편중된 전용 변수는 통합 모델 학습 시 다른 그룹에 적용할 수 없어 결측치를 유발하므로 과감히 탈락

디지털 정보격차 기반 3단계 적응 수준 분류와 설명가능한 분석

3.2.6. 데이터 set 분할

전처리가 완료된 데이터를 train, validation, test = 70:15:15 의 비율로 데이터 셋을 나눈 뒤 해당 파일을 csv 형식으로 저장하였다. data\preprocessed\train.csv, data\preprocessed\val.csv, data\preprocessed\test.csv에 파일은 각각 185개 열을 가지며, 결측 처리가 완료된 상태에서 사용되었다. 라벨링에 쓰인 전처리 완료 후 데이터는 다음과 같다.

구분	행 수	열 수	결측
train	18,799	185	0
validation	6,267	185	0
test	6,267	185	0
전체	31,333	185	0

집단별 표본 구성은 일반국민 13,685명, 고령층 4,448명, 장애인 4,400명, 농어민 4,400명, 저소득층 4,400명이다. 연도별 표본은 2024년 15,654명, 2025년 15,679명이다.

구분	표본 수
일반국민	13,685
고령층	4,448
장애인	4,400
농어민	4,400
저소득층	4,400

4. Experiment

4.1 데이터셋 설명

라벨링 작업은 전처리된 데이터에서 디지털 적응 수준을 구성할 feature를 선별하고, K-means 군집 결과를 3단계 digital_stage로 매핑하는 방식으로 진행했다. 작업 범위는 K-means 입력 feature 선정, 영역별 점수 구성, 군집 수 비교, 군집별 평균 특성 확인, cluster-to-stage mapping 생성, labeled split 파일 저장으로 구성된다. 최종 라벨 데이터는 전처리 완료 후 데이터에 row_id, cluster, digital_stage, digital_stage_name 열을 추가한 최종 모델 학습용 데이터이다.

(data\labeled\train_labeled.csv, data\labeled\val_labeled.csv, data\labeled\test_labeled.csv)

최종 예측 대상인 digital_stage는 외부에서 주어진 정답 라벨이 아니라 K-means 군집화와 연구팀의 단계 해석을 결합해 생성한 pseudo-label이다. 이 라벨은 설문 응답 feature를 바탕으로 구성한 단계값이므로, 이후 지도학습 모델의 성능은 실제 디지털 적응 수준에 대한 절대적 판별 성능보다 설계된 단계 구조를 얼마나 일관되게 재현하는지를 나타낸다.


K-means 라벨 생성에는 110개 feature를 사용했다. feature 목록은

data/labeled/kmeans_feature_selection.csv에 저장되어 있으며, 각 feature는 디지털 적응 수준과 직접 관련된 핵심 변수로 표시되어 있다. 입력 변수에는 디지털 기기 보유 및 접근, 기본 조작 능력, 인터넷 이용 시기, 인터넷 이용 시간, 온라인 서비스 이용, AI 인지와 사용 경험 관련 문항이 포함되었다.

라벨링 단계에서는 feature들을 표준화한 뒤 다섯 개 영역 점수로 정리했다. 영역은 기기 접근 점수, 기본 역량 점수, 이용 시간 점수, 서비스 이용 점수, AI 관련 점수다. digital_activity_index는 이 다섯 개 영역의 scaled mean을 산술평균한 값으로 사용했다. 군집을 단계로 변환할 때에는 학습 데이터 기준 digital_activity_index를 낮은 순서에서 높은 순서로 정렬했다.

디지털 정보격차 기반 3단계 적응 수준 분류와 설명가능한 분석

K-means 라벨 설계에서는 k=3을 최종 설정으로 사용했다. 학습 데이터 기준 inertia는 1,344,407.66이고, 5,000개 표본을 기준으로 계산한 silhouette 값은 0.155다. k=2의 silhouette 값은 0.240이고, k=4는 0.109, k=5는 0.092, k=6은 0.083이다. k=3 선택은 보고서에서 사용할 3단계 적응 수준 구성을 기준으로 한 설정이다.



cluster 1은 1단계 완전 소외, cluster 0은 2단계 부분 적응, cluster 2는 3단계 자립 적응으로 매핑되었다. 1단계는 디지털 활동 점수 -0.544, 기기 접근 점수 -0.242, 기본 역량 점수 -0.810, 이용 시간 점수 -0.477, 서비스 이용 점수 -0.556, AI 관련 점수 -0.637로 나타났다. 2단계는 디지털 활동 점수 0.070, 기기 접근 점수 0.027, 기본 역량 점수 0.289, 이용 시간 점수 0.009, 서비스 이용 점수 -0.103, AI 관련 점수 0.130이다. 3단계는 디지털 활동 점수 0.613, 기기 접근 점수 0.270, 기본 역량 점수 0.656, 이용 시간 점수 0.602, 서비스 이용 점수 0.883, AI 관련 점수 0.657이다.

cluster	digital_stage	단계명	train 기준 표본 수	digital_activity_index
1	1	완전 소외	6,681	-0.538
0	2	부분 적응	7,081	0.072
2	3	자립 적응	5,037	0.613

전체 라벨 분포는 1단계 완전 소외 11,213명, 2단계 부분 적응 11,695명, 3단계 자립 적응 8,425명이다. 비율로는 1단계 35.79%, 2단계 37.32%, 3단계 26.89%다.

digital_stage	단계명	표본 수	비율
1	완전 소외	11,213	35.79%
2	부분 적응	11,695	37.32%
3	자립 적응	8,425	26.89%

집단별 단계 분포는 고령층 1단계 2,428명, 2단계 1,490명, 3단계 530명이다. 농어민은 1단계 2,398명, 2단계 1,423명, 3단계 579명이다. 일반국민은 1단계 2,858명, 2단계 5,472명, 3단계 5,355명이다. 장애인 1단계 1,883명, 2단계 1,528명, 3단계 989명이고, 저소득층은 1단계 1,646명, 2단계 1,782명, 3단계 972명이다.

집단	1단계	2단계	3단계
고령층	2,428	1,490	530
농어민	2,398	1,423	579
일반국민	2,858	5,472	5,355
장애인	1,883	1,528	989
저소득층	1,646	1,782	972

4.2 실험 환경 및 설정

실험은 Python 기반 분석 환경에서 수행되었다. 데이터 처리에는 pandas와 numpy를 사용했고, 전통적 머신러닝 모델 학습과 평가에는 scikit-learn을 사용했다. LightGBM 실험에는 lightgbm과 optuna를 사용했으며, MLP 실험에는

디지털 정보격차 기반 3단계 적용 수준 분류와 설명가능한 분석

PyTorch를 사용했다. 시각화에는 matplotlib과

seaborn을 사용했다. 모델별 결과 파일과 공통 설정 파일은 models/ 하위 디렉터리에 저장했다. 재현성 통제를 위해 주요 실험의 random seed는 42로 고정했다.

지도학습 모델의 공통 입력 feature는 118개이며, 이 가운데 110개는 K-means 라벨 설계에 사용된 feature와 겹친다. 나머지 8개는 디지털 기술 태도와 기기 이용 가능성 관련 추가 feature로 구성했다. 모델 학습시 사용된 feature는 models\MLP\models_feature_selection.csv에서 확인 가능하다.

또한 공통 평가지표 설정은 models/model_config.py에 정리되어 있다. 이 파일은 모델들이 공유하는 입력 feature, 예측 대상, 평가 지표를 정의한다. 예측 대상은 digital_stage이며, 평가 지표는 accuracy, macro_f1, weighted_f1로 고정했다. 모델 간 비교에는 같은 split, 같은 입력 feature, 같은 평가 함수를 사용했다.

모델 학습에 들어가기 전, row_id, cluster, digital_stage, digital_stage_name은 입력 변수에서 분리했다. row_id는 관측치 식별자이고, cluster와 digital_stage 관련 열은 K-means 라벨 생성 및 최종 예측 대상과 직접 연결된다. 최종 모델의 입력은 설문 응답과 파생 feature로 구성하고, digital_stage는 지도학습의 target으로만 사용했다.

라벨 값은 원본 데이터에서 1, 2, 3으로 표현되어 있으며, 모델 학습 단계에서는 0, 1, 2로 변환했다. 이 처리는 scikit-learn과 PyTorch의 다중분류 학습 함수에서 클래스 인덱스를 다루기 위한 형식 통일이다. 결과 해석 단계에서는 class 0, class 1, class 2를 각각 1단계 완전 소외, 2단계 부분 적응, 3단계 자립 적응에 대응시켰다.

K-means 라벨 생성 단계에서는 학습 데이터만 사용해 scaler와 군집 모델을 적용했다. 군집화 대상 feature 수는 110개이고, random_state는 42로 고정했다. K-means의 n_init은 20으로 설정했다. k 값은 2부터 6까지 비교했으며, 최종 설정은 k=3이다.

SVM 실험은 LinearSVC를 중심으로 구성했다. SVM에는 StandardScaler를 적용했다. 클래스 비율 차이를 반영하기 위해 class_weight='balanced'를 설정했다. 하이퍼파라미터 튜닝은 train set 내부의 5-Fold Stratified CV로 수행했으며, 탐색 대상 C 값은 0.01, 0.1, 1.0, 10.0, 100.0이다. 탐색 기준은 F1-macro로 설정했고, max_iter는 3000으로 지정했다. 최종 모델에서는 CalibratedClassifierCV를 사용했다. calibration은 최적 C 값을 결정한 뒤 별도로 수행했다.

LightGBM 실험은 다중분류 Gradient Boosting Tree 구조로 수행했다. 클래스 비율 차이를 반영하기 위해 class_weight='balanced'를 설정했다. 하이퍼파라미터 탐색에는 Optuna의 TPE Sampler를 사용했고, 탐색 횟수는 50회로 설정했다. 주요 탐색 범위에는 num_leaves, max_depth, learning_rate, n_estimators, min_child_samples, subsample, colsample_bytree, reg_alpha, reg_lambda가 포함된다. 학습 중 검증 손실을 기준으로 early stopping을 적용했고, patience는 20으로 설정했다. 최종 모델 저장과 비교에는 검증 F1-macro가 높은 설정을 사용했다. feature importance는 split count와 gain 기준으로 각각 저장했다.

MLP 실험은 118개 입력 feature를 사용하는 다층 퍼셉트론 구조로 구성했다. Stage1 모델은 입력층 118차원, 은닉층 256, 128, 64차원, 출력층 3차원으로 구성되어 있다. 각 은닉층에는 BatchNorm, ReLU, Dropout을 적용했다. 첫 번째와 두 번째 은닉층의 dropout은 0.3이고, 세 번째 은닉층의 dropout은 0.2다.

손실함수는 CrossEntropyLoss, optimizer는 Adam을 사용했다. learning rate는 0.001, batch size는 64, epoch 수는 50으로 설정했다. 학습률 조정에는

ReduceLROnPlateau를 사용했고, validation macro F1이 높은 모델을 최종 가중치로 저장했다.

MLP에서는 Stage1 모델에 더해 Two-Stage Reclassification 실험을 수행했다. Stage1 모델의 예측 확률에서 1순위와 2순위 클래스의 차이가 작은 샘플을 경계 샘플로 두고, 0↔1 및 1↔2 경계에 대해 별도의 이진 보정기를 적용했다. validation set에서 margin threshold를 탐색한 뒤 test set에 같은 기준을 적용했다. 최종 비교에서는 Stage1 MLP 결과와 Two-Stage 보정 후 결과를 구분해 제시했다.

디지털 정보격차 기반 3단계 적용 수준 분류와 설명가능한 분석

모든 모델은 같은 train, validation, test split을 사용했다. SVM은 선형 분류 모델, LightGBM은 tree 기반 boosting 모델, MLP는 다층 신경망 모델로 설정했다. 세 모델의 입력 feature, target, 평가 함수는 동일하게 유지했다.

4.3 학습/검증/테스트 분할 방식

데이터는 전체 31,333명을 대상으로 train, validation, test로 분할했다. 실제 분할 비율은 60:20:20이며, 최종 표본 수는 각각 18,799명, 6,267명, 6,267명이다. 분할 과정에서는 집단별 표본 비율을 유지하기 위해 GROUP 변수를 기준으로 층화 분할을 적용했다.

split	표본 수	비율	용도
train	18,799	60.00%	K-means 라벨 설계, 지도학습 모델 학습
validation	6,267	20.00%	하이퍼파라미터 선택, early stopping, threshold tuning
test	6,267	20.00%	최종 성능 평가

train split은 K-means 라벨 설계의 기준 데이터로 사용했다. scaler와 K-means 모델은 train split에서 적합했고, validation과 test에는 같은 기준을 적용해 digital_stage를 부여했다. 분류 모델 학습과 평가는 라벨이 부착된 train, validation, test 파일을 기준으로 수행했다.

라벨 부착 이후 train split은 1단계 6,681명, 2단계 7,081명, 3단계 5,037명으로 구성되었다. validation split은 1단계 2,294명, 2단계 2,273명, 3단계 1,700명이다. test split은 1단계 2,238명, 2단계 2,341명, 3단계 1,688명이다.

split	1단계	2단계	3단계
train	6,681	7,081	5,037
validation	2,294	2,273	1,700
test	2,238	2,341	1,688

GROUP 기준 분할 결과는 일반국민 train 8,211명, validation 2,737명, test 2,737명이다. 고령층은 train 2,668명, validation 890명, test 890명이다. 장애인, 농어민, 저소득층은 각각 train 2,640명, validation 880명, test 880명으로 배치되었다.

집단	train	validation	test
일반국민	8,211	2,737	2,737
고령층	2,668	890	890
장애인	2,640	880	880
농어민	2,640	880	880
저소득층	2,640	880	880

연도별 분할 결과는 2024년 train 9,404명, validation 3,126명, test 3,124명이다. 2025년은 train 9,395명, validation 3,141명, test 3,143명이다.

연도	train	validation	test
2024	9,404	3,126	3,124
2025	9,395	3,141	3,143

validation split은 모델별 설정 선택에 사용했다. SVM의 하이퍼파라미터는 train set 내부의 5-Fold Stratified CV로 선택했고, validation set은 최종 후보 모델의 성능 확인에 사용했다. LightGBM에서는 validation set을 Optuna 탐색과 early stopping의 기준으로 사용했다. MLP에서는 epoch별 validation macro F1을 추적하고 best checkpoint를 선택하는 기준으로 사용했다. Two-Stage MLP에서는 top1-top2 margin threshold를 선택하는 기준으로 사용했다.

test split은 모델 비교의 최종 기준으로 사용했다. 최종 비교 파일인 models/final_model_summary.csv는 MLP, LightGBM, SVM의 validation accuracy, validation F1-macro, test accuracy, test F1-macro를 함께 기록한다. Two-Stage MLP 결과는 models/MLP/MLP_two_stage_comparison.csv에 저장했다.

digital_stage는 K-means 기반 pseudo-label이다. 평가 과정은 이 pseudo-label을 기준값으로 두고 예측값과의 일치

정도를 계산한다. test 성능은 설계된 디지털 적응 단계 구조에 대한 분류 모델의 재현 성능으로 처리했다.

4.4 평가 지표 정의

평가 지표는 accuracy, F1-macro, F1-weighted를 사용했다. 세 지표는 validation과 test split에 대해 계산했다. 모델별 세부 평가 리포트에는 각 클래스의 precision, recall, f1-score, support를 함께 기록했다.

Accuracy는 전체 샘플 중 예측한 단계가 기준 라벨과 일치한 비율이다. N개의 평가 샘플에서 실제 라벨을 y_i , 예측 라벨을 $y_{\hat{i}}$ 라고 할 때, accuracy는 y_i 와 $y_{\hat{i}}$ 가 같은 샘플 수를 N으로 나눈 값이다. 본 실험에서는 digital_stage를 기준 라벨로 사용했다.

Precision은 특정 단계로 예측된 샘플 가운데 실제로 그 단계에 속한 샘플의 비율이다. 1단계 precision은 모델이 1단계로 분류한 샘플 중 실제 digital_stage가 1단계인 샘플의 비율을 의미한다. Recall은 실제 특정 단계에 속한 샘플 가운데 모델이 그 단계를 맞춘 비율이다. 1단계 recall은 실제 1단계 샘플 중 모델이 1단계로 예측한 샘플의 비율이다.

F1-score는 precision과 recall의 조화평균이다. 특정 단계의 precision을 P, recall을 R이라고 할 때, F1-score는 $2PR/(P+R)$ 로 계산한다. 클래스별 F1-score는 1단계, 2단계, 3단계 각각에 대해 따로 계산했다.

F1-macro는 각 단계의 F1-score를 단순 평균한 값이다. 1단계, 2단계, 3단계가 같은 가중치로 계산에 들어간다. 본 실험의 모델 선택 기준은 validation F1-macro이고, 최종 비교의 중심 지표는 test F1-macro다.

F1-weighted는 각 단계의 F1-score에 해당 단계의 support를 가중치로 적용해 평균한 값이다. support는 평가 데이터에서 해당 단계에 속한 실제 샘플 수를 의미한다. F1-weighted는 전체 평가 데이터의 라벨 분포를 반영한다.

Confusion matrix는 실제 단계와 예측 단계의 조합을 3×3 행렬로 기록한다. 행은 실제 digital_stage, 열은 예측 digital_stage로 둔다. 이 행렬은 1단계↔2단계, 2단계↔3단계처럼 인접 단계에서 발생한 오류와 1단계↔3단계처럼 비인접 단계에서 발생한 오류를 분리해 확인하는 데 사용했다.

Validation 지표는 모델 설정을 선택하는 과정에서 사용했다. SVM의 GridSearchCV scoring 기준은 F1-macro다. LightGBM은 Optuna 탐색과 early stopping 이후 validation F1-macro를 기록했다. MLP는 validation macro F1을 기준으로 best checkpoint를 저장했다. Two-Stage MLP는 validation set에서 top1-top2 margin threshold를 탐색했다.

Test 지표는 최종 모델 비교에 사용했다. test accuracy는 전체 테스트 샘플의 정답률이고, test F1-macro는 1단계, 2단계, 3단계의 F1-score를 같은 비중으로 평균한 값이다. test F1-weighted는 테스트 데이터의 단계별 support를 반영한 평균 F1-score다.

평가 리포트의 class 0, class 1, class 2는 각각 1단계 완전 소외, 2단계 부분 적응, 3단계 자립 적응에 대응한다. scikit-learn의 classification report는 각 class에 대해 precision, recall, f1-score, support를 산출한다. 모델별 evaluation.txt 파일은 validation 결과와 test 결과를 같은 형식으로 기록한다.

4.5 사용 모델 및 알고리즘 설명

모든 모델은 비지도학습을 통해 만들어진 동일한 학습데이터

(data\labeled\train_labeled.csv, data\labeled\val_labeled.csv, data\labeled\test_labeled.csv)

와 동일한 평가지표 및 feature를 사용한다. (models/model_config.py)

4.5.1. MLP

[1] Algoritm

디지털 정보격차 기반 3단계 적용 수준 분류와 설명가능한 분석

- **목적:** 디지털 소외계층의 정보화 수준을 3 단계(1 단계: 완전 소외, 2 단계: 부분 적응, 3 단계: 자립 적응)로 분류하는 다중 클래스 분류(Multi-class Classification) 모델을 구축하고, 모델의 경계 영역 예측 성능을 고도화한다.
- **핵심 방법론:**
 - **Stage 1 (기반 학습):** 입력 특징(118 차원)을 활용하여 클래스별 예측 확률을 도출하는 심층 MLP(Multi-Layer Perceptron)를 학습함.
 - **Stage 2 (보정 알고리즘):** Baseline MLP 가 예측한 소프트맥스 확률 벡터 중, 최상위 확률과 차상위 확률의 차이(Top1-Top2 Margin)가 사용자가 지정한 임계값(Threshold)보다 작은 샘플을 '모호한 경계 샘플(Ambiguous Samples)'로 정의함. 이 경계층 샘플에 대해 사전 학습된 **이진 로지스틱 회귀(Logistic Regression) 보정기**를 추가 적용하여 최종 오분류를 교정하는 'Two-Stage 하이브리드 파이프라인'을 제안함.

[2] Model Architecture

Baseline MLP 모델은 총 4개의 Linear Layer으로 구성된 Fully-Connected Neural Network 구조를 가진다.

- **Input Layer:** 입력 차원 크기는 118
- **Hidden Layers:** 과적합 방지와 학습 안정화를 위해 각 은닉층마다 배치 정규화와 드롭아웃을 병행 배치함.
 - **제 1 은닉층:** 118→ 256 차원 확장 → BatchNorm1d→ ReLU→Dropout (p=0.3)
 - **제 2 은닉층:** 256→ 128 차원 축소 → BatchNorm1d→ ReLU→Dropout (p=0.3)
 - **제 3 은닉층:** 128→64 차원 축소 → BatchNorm1d→ ReLU→Dropout (p=0.2)
- **Output Layer:** 최종 클래스 수인 3 차원으로 출력함. PyTorch 의 연산 특성을 고려하여, 모델의 마지막 Layer 뒤에는 별도의 활성화 함수를 적용하지 않고 선형 로짓 상태 그대로 반환함.

[3] Experimental Pipeline

1. **환경 초기화 및 재현성 확보:** 수치 연산의 일관성을 위해 난수 시드(Seed)를 42로 고정하고 PyTorch 백엔드의 결정론적(Deterministic) 옵션을 활성화함.
2. **데이터 전처리 및 텐서 변환:**
 - Train / Validation / Test 데이터프레임을 로드한 후, 클래스 라벨(1, 2, 3 단계)을 손실 함수 규격에 맞게 0-based 인덱스(0, 1, 2)로 정규화함.
 - 데이터를 PyTorch Tensor로 변환한 후 배치 크기(Batch Size) 64 기반의 DataLoader를 구축함. 학습 데이터셋에 한해 에폭마다 셔플(Shuffle)을 적용함.
3. **Stage 1: MLP 모델 학습 및 검증:** 데이터 로더를 순회하며 순전파 및 역전파 가중치 업데이트를 수행하고, 에폭별로 검증 데이터셋 성능을 평가하여 최적의 가중치 가 파일(best_mlp_model.pth)로 저장됨.
4. **Stage 2: Two-Stage 보정 모델 학습:**
 - Baseline MLP의 예측 결과를 기반으로 오분류 패턴을 다각도로 분석함.

디지털 정보격차 기반 3단계 적용 수준 분류와 설명가능한 분석

- 검증 데이터셋을 활용하여 주요 인접 클래스 쌍(예: 0-1 번 클래스 간, 1-2 번 클래스 간)에 대응하는 개별 이진 로지스틱 회귀 보정기를 학습시키고, 성능을 극대화할 수 있는 최적의 Margin 임계값을 그리드 탐색(Grid Search)으로 식별함.
5. **최종 평가 및 성능 비교:** 완성된 Two-Stage 알고리즘을 독립된 Test 데이터셋에 적용하여 최종 분류 예측 결과를 산출하고, 혼동 행렬(Confusion Matrix) 분석을 통해 보정 전후의 성능 향상 지표를 검증함.

[4] Experimental Setup

- **손실 함수 (Loss Function):** 다중 클래스 분류의 표준 목적 함수인 교차 엔트로피 손실 함수를 채택함.
- **최적화 기법 (Optimizer):** 가중치 최적화를 위해 Adam 옵티마이저를 사용하며, 초기 학습률(Learning Rate)은 0.001 로 설정함.
- **학습률 스케줄러 (Learning Rate Scheduler):** ReduceLROnPlateau 를 도입하여, 검증 데이터의 Macro F1-score 가 5 회 에폭 동안 개선되지 않을 경우 학습률을 0.5 배 감쇠시킴으로써 국소 최적해(Local Minima) 탈출을 도모함.
- **조기 종료 (Early Stopping) 및 수렴 결과:**
 - 최대 에폭은 50 으로 지정하되, Validation Macro F1-score 지표가 10 회 에폭 동안 최댓값을 경신하지 못하면 학습을 조기 중단하도록 설계함.
 - **실제 실험 수렴 결과:** 본 실험에서 모델은 **11 번째 에폭**에서 검증 Macro F1-score 최고점(약 0.778)을 기록한 후 성능이 정체되어, **21 번째 에폭**에서 **조기 종료(Early Stopping)** 조건이 발동하며 안정적으로 수렴함.

[5] Evaluation Metrics : 전체 모델에 공통 정의된 평가지표인 Accuracy, F1 Macro, F1 Weighted를 활용해 모델을 평가하고, 모든 모델의 공통 시각화 요소인 세 가지 그래프를 통해 다각적인 정성 평가를 수행하였다. 먼저 혼동행렬 (Confusion Matrix) 히트맵으로 실제 역량 단계와 모델 예측 간의 세부 오답 패턴 및 매칭 빈도를 규명하였고, 막대그래프를 통해 1~3단계별 실제 정답 수와 모델의 예측 샘플 수를 대비하여 특정 클래스에 대한 예측 편향과 분포 불균형을 검토하였다. 마지막으로 파이차트를 활용해 전체 테스트 데이터셋의 최종 정·오답 비율을 시각화함으로써 모델의 직관적인 정확도를 산출하였다.

추가적으로 Two -Stage 보정 전 후의 confusion matrix를 비교해 개선결과를 확인하였다.

4.5.2. LightGBM

[1] Algorithm

목적: 디지털 소외계층의 정보화 수준을 3단계(1단계: 완전 소외, 2단계: 부분 적응, 3단계: 자립 적응)로 분류하는 다중 클래스 분류(Multi-class Classification) 모델을 구축하되, 트리 앙상블 기반의 해석 가능한 그래디언트 부스팅 프레임워크를 활용한다.

핵심 방법론:

디지털 정보격차 기반 3단계 적용 수준 분류와 설명가능한 분석

- 학습 알고리즘: 그래디언트 부스팅 (Gradient Boosting):

순차적으로 약한 학습기(결정 트리)를 추가하며 이전 트리의 잔차(residual error)를 보정하는 앙상블 방식이다. 각 트리는 이전 모델의 오차를 줄이는 방향으로 학습된다.

- 계산 효율화: 히스토그램 기반 분기 탐색 (Histogram-based Split Finding):

연속형 feature를 max_bin 개의 이산 구간(bin)으로 양자화하여 분기 탐색 연산량을 크게 줄인다. 전통적인 Pre-sorted 방식 대비 메모리 효율과 속도 모두 개선된다.

- LightGBM 고유 전략: 리프 중심 트리 성장 (Leaf-wise Tree Growth):


손실 감소 폭이 가장 큰 리프를 우선적으로 분기하는 Leaf-wise 전략을 채택한다. 이는 균형 트리(Level-wise) 방식보다 동일 리프 수에서 더 낮은 손실을 달성하지만, max_depth와 min_child_samples 등의 정규화 파라미터로 과적합을 제어한다.

- 불균형 처리: 클래스 불균형 보정:

1단계(6,681개), 2단계(7,081개), 3단계(5,037개)의 클래스 불균형을 완화하기 위해 class_weight='balanced'를 적용하여 소수 클래스의 손실 가중치를 자동 조정한다.

[2] Experimental Pipeline

- **환경 초기화 및 재현성 확보:** 난수 시드(Seed)를 42로 고정하고, Optuna의 TPE Sampler에도 동일 시드를 적용하여 실험 재현성을 확보한다.
- **데이터 전처리:** Train / Validation / Test 데이터프레임을 로드한 후, 클래스 라벨(1, 2, 3단계)을 0-based 인덱스(0, 1, 2)로 정규화한다. LightGBM은 내부적으로 스케일링을 수행하므로 별도의 Feature Scaling은 적용하지 않는다.
- **Baseline 학습:** 기본 파라미터(num_leaves=31, learning_rate=0.1, n_estimators=200)로 먼저 학습하여 튜닝 전 기준점(Baseline)을 측정한다.
- **Optuna 하이퍼파라미터 탐색:** TPE Sampler로 50회 Trial을 수행하며 Validation F1-macro를 최대화하는 파라미터 조합을 탐색한다. 각 Trial에는 Early Stopping(patience=20)이 적용된다.
- **최종 모델 학습 (학습 곡선 동시 기록):** 최적 파라미터로 최종 모델을 학습하되, record_evaluation 콜백을 활용하여 단일 학습 과정에서 Train/Validation의 반복별 손실 값을 동시에 기록한다. 이를 통해 추가적인 재학습 없이 학습 곡선을 생성한다.
- **평가 및 시각화:** model_config.py의 공통 evaluate() 함수로 Validation 및 Test 성능을 측정하고, 학습 곡선, 혼동 행렬, 예측 분포, Feature Importance를 저장한다.



디지털 정보격차 기반 3단계 적용 수준 분류와 설명가능한 분석

[3] Hyperparameter Optimization

LightGBM은 num_leaves, learning_rate 등 성능에 민감한 하이퍼파라미터가 다수 존재하므로, 베이지안 최적화 기반의 Optuna 프레임워크를 도입하여 체계적인 탐색을 수행하였다.

탐색 전략: TPE(Tree-structured Parzen Estimator) Sampler

단순 랜덤 탐색이나 격자 탐색(Grid Search)과 달리, TPE는 이전 시도의 결과를 확률 모델로 학습하여 성능이 높을 것으로 예측되는 파라미터 구간을 집중 탐색한다. 탐색 횟수(N_TRIALS=50)를 설정하고, 각 Trial에서 Validation F1-macro를 목적 함수로 최대화하는 방향으로 작동한다.

표. LightGBM 하이퍼파라미터 탐색 범위

파라미터	탐색 범위	설명
num_leaves	31 ~ 255	리프 노드 수. 클수록 복잡한 패턴 학습, 과적합 위험 증가
max_depth	3 ~ 12	트리 최대 깊이. 작을수록 단순 모델
learning_rate	0.01 ~ 0.3 (log)	학습 보폭. 작을수록 안정적, 느린 수렴
n_estimators	100 ~ 1000 (step 50)	트리 개수. Early Stopping으로 자동 조절
min_child_samples	5 ~ 100	리프 최소 샘플 수. 클수록 과적합 방지
subsample	0.5 ~ 1.0	행 샘플링 비율. 랜덤성 부여로 일반화 향상
colsample_bytree	0.5 ~ 1.0	열(Feature) 샘플링 비율
reg_alpha	1e-4 ~ 10 (log)	L1 정규화 강도
reg_lambda	1e-4 ~ 10 (log)	L2 정규화 강도
min_split_gain	0.0 ~ 1.0	분기 최소 정보 이득. 불필요한 분기 억제
max_bin	128 ~ 512	연속형 Feature 히스토그램 bin 수

조기 종료(Early Stopping): 각 Trial 내에서 n_estimators가 Validation Loss를 20회(patience=20) 연속으로 개선하지 못할 경우 학습을 중단하여 최적의 반복 수를 자동 결정한다.

표. Optuna 탐색 결과 - 최적 하이퍼파라미터

파라미터	최적값	해석
num_leaves	55	중간 복잡도의 트리 구조
max_depth	3	얕은 트리로 과적합 억제
learning_rate	0.0871	적당한 학습 보폭
n_estimators (실제)	350	Early Stopping에 의해 결정
min_child_samples	53	리프 최소 53개 샘플 요구
subsample	0.954	행의 95.4% 샘플링
colsample_bytree	0.625	Feature의 62.5% 샘플링
reg_alpha / reg_lambda	0.011 / 0.599	약한 L1, 중간 L2 정규화
min_split_gain	0.229	최소 이득 기준으로 불필요 분기 차단
max_bin	157	중간 수준의 히스토그램 bin

[4] Experimental Setup

- 손실 함수 (Loss Function): 다중 클래스 분류의 표준 목적 함수인 교차 엔트로피 손실(multi_logloss)을 채택한다.
- Feature Importance 기준: LightGBM의 feature_importances_는 기본적으로 Split Count(해당 Feature가 분기에 사용된 횟수) 기준이다. 이와 더불어 Gain(해당 Feature로 얻은 정보 이득의 합계) 기준을 추가 산출하여 두 관점을 비교함으로써 해석의 신뢰도를 높인다.
- 출력 경로: 학습 결과 및 시각화 파일은 models/LightGBM/ 디렉토리에 저장된다.

디지털 정보격차 기반 3단계 적용 수준 분류와 설명가능한 분석

- 경로 설정: 하드코딩을 배제하고 `find_project_root()` 함수와 `PROJECT_ROOT` 환경변수를 활용하여 어떤 PC·OS에서도 경로 수정 없이 동작하도록 설계한다.

[5] Evaluation Metrics

전체 모델에 공통 정의된 평가 지표인 Accuracy, F1 Macro, F1 Weighted를 활용하여 모델을 평가하고, 공통 시각화 요소인 세 가지 그래프를 통해 다각적인 정성 평가를 수행하였다. 혼동 행렬(Confusion Matrix) 히트맵으로 클래스 간 오분류 패턴을 규명하였고, 막대그래프로 단계별 실제 정답 수와 예측 샘플 수를 대비하였으며, 파이차트로 전체 정·오답 비율을 시각화하였다. LightGBM 고유의 시각화로는 Train/Validation 손실 곡선(학습 곡선)과 Feature Importance 비교 차트(Split Count 기준 및 Gain 기준)를 추가 제공하여 모델 학습 과정과 변수 중요도를 심층 분석한다.

4.5.3. SVM

[1] Algorithm

목적: 디지털 소외계층의 정보화 수준을 3단계로 분류하는 다중 클래스 분류 모델을 구축하되, 고차원 Feature 공간에서 클래스 간 최대 마진(Maximum Margin) 결정 경계를 학습하는 선형 SVM을 활용한다.

핵심 방법론:

- **분류 전략:** LinearSVC 기반 다중 클래스 분류:
 - sklearn의 LinearSVC는 One-vs-Rest(OvR) 전략으로 다중 클래스를 처리한다. 각 클래스에 대해 독립적인 이진 선형 분류기를 학습하며, 예측 시 가장 높은 결정 함수 값(Decision Function)을 갖는 클래스를 최종 예측으로 선택한다.
- **Feature 스케일링:** StandardScaler 필수 적용:
 - SVM은 Feature 간 스케일 차이에 민감하여, 학습 전 StandardScaler로 평균 0, 표준편차 1로 정규화한다. 스케일러는 Pipeline 내부에 포함되어 데이터 누수(Data Leakage) 없이 각 교차검증 Fold에서 독립적으로 fit된다.
- **CalibratedClassifierCV:** Calibration (확률 추출):
 - LinearSVC는 기본적으로 확률값을 출력하지 않는다. Platt Scaling(sigmoid 방식)을 적용한 CalibratedClassifierCV로 감싸 확률 기반 출력을 가능하게 한다. Calibration은 최적 파라미터 확정 후 1회만 수행하여 학습 비용을 최소화한다.
- **불균형 처리:** 클래스 불균형 보정:
 - `class_weight='balanced'`를 적용하여 소수 클래스(3단계, 5,037개)에 높은 손실 가중치를 부여함으로써 예측 편향을 완화한다.


[2] Experimental Pipeline

- **환경 초기화 및 재현성 확보:** 난수 시드(Seed)를 42로 고정하고, GridSearchCV의 StratifiedKFold에도 동일 시드를 적용한다.
- **데이터 전처리:** Train / Validation / Test 데이터프레임을 로드한 후, 클래스 라벨(1, 2, 3단계)을 0-based 인

디지털 정보격차 기반 3단계 적용 수준 분류와 설명가능한 분석

덱스(0, 1, 2)로 정규화한다. StandardScaler는 Pipeline 내부에서 처리되므로 사전 스케일링은 수행하지 않는다.

- **Baseline 학습:** C=1.0의 기본 파라미터로 먼저 학습하여 튜닝 전 기준점을 측정한다. (Val F1-macro: 0.9898, Test F1-macro: 0.9861)
- **GridSearchCV 하이퍼파라미터 탐색:** C 6개 후보와 loss 2개 후보의 조합(총 12가지)을 Stratified 5-Fold CV로 평가하여 최적 조합(C=1000, loss=squared_hinge)을 선택한다.
- **최종 모델 학습:** 최적 파라미터로 Pipeline(StandardScaler + LinearSVC)을 전체 Train 데이터로 학습한다. Calibration은 Pipeline 전체를 CalibratedClassifierCV로 감싸 raw X_train을 입력함으로써 데이터 누수 없이 수행한다.
- **평가 및 시각화:** model_config.py의 공통 evaluate() 함수로 성능을 측정하고, GridSearch C 탐색 곡선, 혼동 행렬, 예측 분포, Feature 중요도(클래스별 coef 및 Permutation Importance)를 저장한다.



[3] Hyperparameter Optimization

SVM의 핵심 하이퍼파라미터는 정규화 강도(C)와 손실 함수(loss)이며, 탐색 공간이 $6 \times 2 = 12$ 개 조합으로 제한적이므로, 전수 탐색 방식인 GridSearchCV를 채택하여 모든 조합을 체계적으로 평가하였다.

탐색 전략: GridSearchCV with Stratified 5-Fold Cross Validation

전체 Train 데이터를 클래스 비율을 유지하며 5개의 Fold로 분할하고, 각 조합에 대해 4개 Fold를 학습 데이터, 1개 Fold를 검증 데이터로 교차 평가한다. F1-macro를 기준 지표로 최적 조합을 선택한다.

학습 비용 절감 설계 — Calibration 분리:

- 기존 구조 (비효율): GridSearchCV 내부에 CalibratedClassifierCV 포함 $\rightarrow 6 \times 2 \times 5(\text{Fold}) \times 3(\text{Calibration Fold}) = 180$ 회 학습
- 개선 구조 (적용): GridSearch 단계에서 Calibration 제외 $\rightarrow 6 \times 2 \times 5(\text{Fold}) = 60$ 회 학습, 이후 최적 파라미터로 Calibration 1회 수행

탐색 파라미터:

- C (정규화 강도): [0.01, 0.1, 1.0, 10.0, 100.0, 1000.0] — 마진과 오분류 허용 정도의 균형을 제어한다. C가 클수록 오분류를 억제하여 결정 경계가 좁아지고, 작을수록 마진을 넓게 유지한다.
- loss (손실 함수): ['hinge', 'squared_hinge'] — hinge는 표준 SVM 손실로 이상치에 덜 민감하며,

디지털 정보격차 기반 3단계 적용 수준 분류와 설명가능한 분석

squared_hinge는 hinge의 제곱으로 마진 침범 샘플에 강한 패널티를 부여하여 수렴 속도가 빠르다.

표 5. GridSearchCV C 탐색 결과

C	CV F1-macro (mean)	CV F1-macro (std)	loss*	순위
0.01	0.9550	0.0034	-	6
0.1	0.9759	0.0024	-	5
1.0	0.9874	0.0012	-	4
10.0	0.9919	0.0009	-	3
100.0	0.9925	0.0011	-	2
1000.0	0.9928	0.0011	squared_hinge	1

[4] Experimental Setup

- **손실 함수:** hinge 및 squared_hinge를 GridSearch로 탐색하여 최적 손실 함수를 데이터 기반으로 결정한다. 최종 선택: squared_hinge.
- **Feature 중요도 분석 (이중 방법론):** SVM의 Feature 중요도는 두 가지 방법으로 분석한다.
 - coef 절댓값 (클래스별 분리): LinearSVC 내부 선형 계수를 1단계, 2단계, 3단계별로 분리하여 각 클래스 예측에 기여하는 Feature를 개별적으로 파악한다. 단, Calibration 내부 계수의 부분 정보만 반영되므로 '대략적 순위' 참고용으로 활용한다.
 - Permutation Importance (주요 해석 기준): Validation Set에서 각 Feature를 무작위로 섞었을 때 F1-macro가 하락하는 폭을 10회 반복 평균으로 계산한다. 모델 구조에 무관하게 실제 예측 기여도를 측정하는 신뢰도 높은 방법으로 주요 해석 기준으로 활용한다.
- **Calibration 데이터 누수 방지:** StandardScaler를 Pipeline 내부에 포함하여 CalibratedClassifierCV에 raw X_train을 입력한다. 이를 통해 Calibration 내부의 각 교차검증 Fold에서 스케일링이 독립적으로 수행되어 검증 Fold 정보의 사전 반영(데이터 누수)을 방지한다.
- **출력 경로:** 학습 결과 및 시각화 파일은 models/SVM/ 디렉토리에 저장된다.
- **경로 설정:** find_project_root() 함수와 PROJECT_ROOT 환경변수를 활용하여 플랫폼 독립적 경로 설정을 구현한다.

[5] Evaluation Metrics

전체 모델에 공통 정의된 평가 지표인 Accuracy, F1 Macro, F1 Weighted를 활용하여 모델을 평가하고, 공통 시각화 요소인 혼동 행렬, 클래스별 예측 분포 막대그래프, 정·오답 파이차트를 통해 다각적인 정성 평가를 수행하였다. SVM 고유의 시각화로는 GridSearch C 탐색 곡선(C 값에 따른 CV F1-macro 변화)과 Feature 중요도 비교 차트(클래스별 coef 및 Permutation Importance)를 제공하여 하이퍼파라미터 탐색 과정과 Feature 기여도를 심층 분석한다.

** SVM 추가실험- feature 가중치 적용 학습

방법

Q10이 모델을 과도하게 지배하지 않도록, permutation importance를 기준으로 feature별 가중치를 역비례 방식으로 재계산해 SVM을 재학습했다. Q10 계열 feature에는 추가 패널티를 부여했고, StandardScaler 이후 FixedFeatureWeighter를 적용해 스케일링이 가중치 효과를 상쇄하지 않도록 파이프라인 순서를 조정했다. 최종적으로 원본 모델과 가중치 적용 모델을 동일한 validation/test셋에서 직접 비교했다.

디지털 정보격차 기반 3단계 적용 수준 분류와 설명가능한 분석


정량 결과

- Validation Accuracy: 0.994096 → 0.994256
- Validation F1-macro: 0.993963 → 0.994109
- Test Accuracy: 0.992660 → 0.992820
- Test F1-macro: 0.992716 → 0.992886

성능은 거의 동일하게 유지되었고 오히려 소폭 개선되었다.


구조 변화

Q10의 permutation importance 순위가 크게 하락했고, 대신 Q14A_4, Q7_3, Q8_3, Q9_2 등의 feature가 상위권으로 이동했다. Confusion Matrix는 거의 동일하지만 일부 2단계 오분류 패턴에 미세한 변화가 있었다. 즉, 특정 변수(Q10)에 집중되어 있던 예측 기여도가 여러 feature로 더 고르게 분산되었다.



추가 검증: Q10 제거/단독 실험

- Q10의 실제 의존도를 더 명확히 확인하기 위해 두 가지 대조 실험을 추가로 수행했다.
- Q10 제거 모델 (Q10-drop): Q10 없이 나머지 feature만 사용
- Q10 단독 모델 (Q10-only): Q10(및 Q10 계열)만 사용



- Q10-drop (Q10 제외 모델): Test F1-macro 0.9927 → 0.9914 (약 -0.0013)로 소폭 하락. → Q10은 실제로 유의미한 정보를 담고 있음을 의미.
- Q10-only (Q10 계열만 사용한 모델): Test F1-macro 0.3162로 성능이 크게 붕괴. → Q10이 강한 신호이긴 하지만

디지털 정보격차 기반 3단계 적용 수준 분류와 설명가능한 분석

단독으로는 절대 충분하지 않음을 의미.

- **SVM_weighted (가중치 적용 모델):** Test F1-macro 0.9929로 원본 대비 소폭 상승하며 세 모델 중 가장 균형적인 결과를 보임. → Q10 과의존을 완화하면서도 성능은 유지/개선됨.

최종 결론

Q10은 중요한 변수이지만, 모델의 전체 성능은 다수 feature의 결합에서 나온다. Feature reweighting은 Q10에 대한 과도한 집중을 완화하면서도 예측력을 유지(오히려 소폭 개선)하는 데 효과적이었으며, 이는 "성능 유지 + 해석 안정성 개선"이라는 목적에 부합하는 결과다.


5. Results

5.1. 주요 정량 결과

모델	val Acc.	Val F1	Test Acc.	Test F1
MLP	0.9788	0.9785	0.9748	0.9751
LightGBM	0.9818	0.9816	0.9794	0.9796
SVM	0.9939	0.9938	0.9925	0.9926
SVM- weighted	0.9942	0.9941	0.9928	0.9929
MLP Two-Stage	0.9944	0.9944	0.9935	0.9935

표. 모델별 핵심 성능 비교

전체 성능 비교에서는 accuracy, F1-macro, 일반화 격차를 함께 보아야 한다. 단일 모델 기준 최고 성능은 SVM 이었고, LightGBM 이 뒤를 이었으며, MLP 는 후처리 전략에서 강점을 보였다. Test F1-macro 는 MLP 0.9751, LightGBM 0.9796, SVM 0.9926 으로 나타났고, SVM 은 validation 과 test 모두에서 가장 높은 수치를 유지했다.



단일 모델 기준으로는 SVM 이 Validation/Test 모두에서 가장 높은 성능을 기록했다. 특히 Test F1-macro 는 SVM 0.9927, LightGBM 0.9796, MLP 0.9751 순이었고, MLP 는 Two-Stage 보정 구조를 적용했을 때 0.9935 로 추가 향상을 보였다. 즉, 단순 비교에서는 SVM 이 가장 안정적이고, 구조적 후처리까지 포함하면 MLP 도 매우 경쟁력 있는 결과를 냈다.

디지털 정보격차 기반 3단계 적용 수준 분류와 설명가능한 분석

5.2. 표/그림/시각화를 활용한 비교





Figure 3. Test per-class F1 comparison




클래스별 F1 과 recall 은 단순 accuracy 보다 더 중요한 비교 기준이다. 특히 본 프로젝트에서는 2 단계가 저활용과 고활용 사이의 경계 클래스를 포함하기 때문에, 어떤 모델이 2 단계를 얼마나 안정적으로 잡아내는지 핵심 쟁점이 된다.


Stage 2 recall 은 MLP baseline 0.9594, LightGBM 0.9714, SVM 0.9893 이었다. 세 모델 모두 Stage 1:3 보다 Stage 2가 더 어렵지만, SVM 이 가장 균형 잡힌 분류를 보였고, MLP 는 후속 보정이 필요한 경향이 뚜렷했다.

1) MLP 결과 비교: Baseling vs Two-Stage


MLP - Test Set 예측 결과




실제 vs 예측 비교




MLP - Two-Stage 개선 후 Test Set 예측 결과






실제 vs 예측 비교



디지털 정보격차 기반 3단계 적용 수준 분류와 설명가능한 분석




2) LightGBM 결과 비교: 탐색, 수렴, 중요도



디지털 정보격차 기반 3단계 적용 수준 분류와 설명가능한 분석

3) SVM 결과 비교: 규제 탐색, 예측, 중요도



MLP는 baseline 성능만 보면 SVM 보다 낮지만, Two-Stage 구조를 적용했을 때 중간 단계 보정 효과가 가장 극적으로 나타났다. 따라서 MLP 파트는 단일 모델 성능보다도 '경계 샘플 보정 전략이 실제로 통하는가'를 보여주는 사례로 읽는 것이 적절하다. Test 기준으로 Accuracy는 0.9746 에서 0.9935 로, F1-macro 는 0.9751 에서 0.9935 로, 2 단계 recall 은 0.9594 에서 0.9868 로 개선되었다. 이는 Stage 2 처럼 경계적인 표본을 별도 규칙으로 재분류하는 전략이 실제로 오분류를 줄였음을 의미한다.

디지털 정보격차 기반 3단계 적용 수준 분류와 설명가능한 분석





Figure 8. Improvement summary from baseline to final setting




LightGBM 은 트리 기반 모델로서 비선형 상호작용을 반영할 수 있고, Optuna 탐색과 early stopping 을 통해 안정적인 성능을 확보했다. 이 페이지의 그래프는 LightGBM 이 어떻게 탐색되었고, 어디까지 수렴했으며, 어떤 특성 집합에 크게 의존했는지를 함께 보여준다. LightGBM 의 test F1-macro 는 0.9796 였고, best iteration 은 531 이었다. Gain 기준 중요 변수는 소수의 강력한 분기 문항에 집중되었고, split count 와 gain 을 함께 볼 때 모델이 자주 쓰는 변수와 실제 이득이 큰 변수를 구분할 수 있다.

SVM 은 본 프로젝트의 대표 단일 모델이다. 이 페이지는 규제 강도 탐색 결과, 최종 테스트 분포, 그리고 전역 중요도를 한 장에 묶어, SVM 을 왜 최종 중심 모델로 설명할 수 있는지 보여준다. SVM 은 best C=1000.0 에서 test F1-macro 0.9927 를 기록했다. 2 단계 recall 도 0.9893 으로 가장 높았으며, permutation importance 기준으로 Q10, Q8_3, Q7_3, Q14A_4 등이 핵심 분리 변수로 나타났다.

정리하면 SVM 은 가장 높은 성능과 가장 작은 일반화 격차를 동시에 보였고, LightGBM 은 안정적인 대안이었으며, MLP 는 Two-Stage 구조에서 가장 큰 개선 폭을 보였다. PCA 에서도 Stage 2 가 Stage 1:3 사이에 놓여, 중간 단계의 구조적 어려움이 시각적으로 확인된다.

6. Analysis / Discussion

6.1. 결과 해석




SVM 이 강한 이유는 survey feature 가 충분히 구조화된 상태에서 선형 분리만으로도 stage 경계가 뚜렷하게 형성되었기 때문이다. Validation 과 test 간 generalization gap 도 작아, 복잡한 비선형 모델보다 안정적이었다. 반면 LightGBM 은

Stage 2 가 어려운 이유는 내부적으로 두 방향의 특징이 섞여 있기 때문이다. Stage 1 은 낮은 접근·역량·활용이, Stage 3 은 높은 활용과 적극적 참여가 비교적 명확하지만, Stage 2 는 두 극단 사이의 과도기적 사례를 포함한다. 그래서 MLP Two-Stage 처럼 불확실한 경계 샘플을 별도 로직으로 처리하는 방법이 특히 유효했다.

6.2. XAI 결과와 의미

전역 XAI 해석 비교



국소 설명에서도 같은 패턴이 확인된다. Stage 1 사례는 ‘인터넷을 오래 사용하지 않음’, ‘파일 전송·콘텐츠 편집·사회참여 경험이 낮음’이 예측을 강화한다. Stage 3 사례는 공공서비스, 정보생산, 경제활동, 적극적 온라인 참여가 양의 기여를 보인다. Stage 2 사례는 긍정·부정 특징이 혼합되어 있어, 경계성이 국소 설명 수준에서도 드러난다.


6.3. 실패사례, 한계점, 개선 방향

본 연구는 디지털 활동성 단계를 예측하는 과정에서 높은 분류 성능을 확인했지만, 몇 가지 한계도 함께 가진다. 첫째, LightGBM 모델의 validation 성능은 다소 낙관적으로 나타났을 가능성이 있다. Optuna를 활용한 하이퍼파라미터 탐색과 early stopping 과정에서 동일한 validation set을 반복적으로 참조했기 때문이다. 이 경우 모델이 validation set에 간접적으로 맞춰질 수 있어, validation 성능이 실제 일반화 성능보다 높게 보일 수 있다. 따라서 최종 모델 비교에서는 validation 성능보다 test set 성능을 중심으로 해석하는 것이 안전하다.

둘째, 분석 대상의 범위에도 한계가 있다. 본 연구에서는 공통 문항과 데이터 안정성을 고려해 북한이탈주민과 결혼이민자를 제외하고 분석을 진행했다. 이로 인해 고령층, 농어민, 장애인, 저소득층 등 주요 취약계층에 대한 비교는 가능했지만, 취약계층 전반으로 결과를 일반화하는 데는 한계가 있다. 특히 디지털 격차는 집단별 생활 조건, 제도 접근성, 언어·문화적 배경에 따라 다르게 나타날 수 있기 때문에, 더 다양한 집단을 포함한 후속 분석이 필요하다.

디지털 정보격차 기반 3단계 적용 수준 분류와 설명가능한 분석

셋째, pseudo-label 자체의 한계도 존재한다. 본 연구의 stage label은 원래 데이터에 존재하던 정답 라벨이 아니라, 디지털 활동 관련 변수들을 바탕으로 군집화한 뒤 해석적으로 부여한 라벨이다. 따라서 모델이 예측한 것은 절대적인 정답이라기보다, 연구자가 설계한 디지털 활동성 단계에 가까운 분류 결과다. 이 점에서 높은 정확도는 모델이 실제 사회적 상태를 완벽히 예측했다는 의미라기보다, 군집 기반 stage 구조를 안정적으로 재현했다는 의미로 해석해야 한다.



향후 연구에서는 이러한 한계를 보완하기 위해 몇 가지 방향을 고려할 수 있다. 먼저, 모든 집단에 공통으로 존재하는 문항만을 추려 축소된 feature space를 구성하면 북한이 탈주민과 결혼이민자까지 포함한 분석이 가능하다. 또한 집단별로 일부 문항이 다를 경우, 공통 과제와 집단별 과제를 함께 학습하는 다중 태스크 학습 방식을 적용할 수 있다.

또한 stage가 1단계, 2단계, 3단계처럼 순서를 가진다는 점을 고려하면, 일반적인 다중분류뿐 아니라 ordinal classification을 적용할 수 있다. 이 방식은 1단계와 3단계를 완전히 별개의 범주로만 보는 것이 아니라, 낮음에서 높음으로 이어지는 순서형 구조를 반영할 수 있다는 장점이 있다. 아울러 semi-supervised label refinement를 통해 군집 기반 pseudo-label을 반복적으로 보정하면, stage label의 안정성을 높일 수 있다. 마지막으로 집단별 fairness 분석을 수행해 특정 사회집단에서 예측 성능이 낮거나 오분류가 집중되는지 확인한다면, 모델의 성능뿐 아니라 사회적 타당성까지 함께 평가할 수 있을

것이다.

7. Conclusion

본 프로젝트는 공식 디지털정보격차 조사 데이터를 활용해 개인의 디지털 적응 수준을 3 단계로 정의하고, 이를 설명 가능한 분류 문제로 재구성했다. 전처리 단계에서는 그룹별 변수 체계와 구조적 결측을 정교하게 정리했고, K-means 기반 pseudo-label 설계는 학력·소득·집단 구성 차이로 타당성을 점검했다. 비교 실험에서는 단일 모델 기준 SVM 이 가장 높은 성능과 가장 작은 일반화 격차를 보였고, MLP 는 Two-Stage 구조를 통해 경계 샘플 보정 가능성을 확인했다.

정책적으로는 ‘접근 격차’보다 ‘역량과 활용 격차’가 핵심 문제라는 점을 개인 단위 예측 수준에서 다시 확인했다는 의미가 있다. 실무적으로는 공공 설문 데이터에서도 설명 가능한 stage 분류 체계를 설계할 수 있음을 보여준다. 향후에는 외부 검증, 집단별 fairness 평가, 더 넓은 취약계층 포함, 실제 교육·지원 프로그램과 연계한 intervention design으로 확장할 수 있다.

*참고 문헌

과학기술정보통신부. 2026. 「2025 년 디지털 정보격차·웹 접근성·스마트폰 과의존 실태조사 결과 발표」. 3 월 26 일.

김현정, 김범수, 김미예. 2024. 「코로나-19 확산 시기별 디지털 격차: 모바일 인터넷 이용량 증가를 중심으로」. 『지식경영연구』 25(1): 193-215.

김효주, 홍석호, 장은하. 2026. 「노인의 디지털 정보화 수준이 인공지능 서비스 활용도에 미치는 영향: 디지털 조력자 유형 비교를 중심으로」. 『보건사회연구』 46(1): 602-621.

이기호. 2019. 「지능정보사회에서의 디지털 정보 격차와 과제」. 『보건복지포럼』 28: 16-28.

이민상. 2020. 「디지털격차의 지식격차에 대한 영향 연구: 지능정보사회에 대한 지식격차를 중심으로」. 『사회과학연구』 36(2): 121-145.

정병호, 주형근. 2022. 「디지털 정보 서비스와 지능정보사회에서의 세대별 디지털 격차 연구」. 『e-비즈니스연구』 23(1): 3-19.