

2026-1 기계학습기초 팀 프로젝트 Final Report

김성민 김민재 손주영 권희원

아주대학교 인공지능융합학과

{kimsung0114, kimmj129, sonjunwha, mjsrnjs}@ajou.ac.kr

제출일: 2026 년 6 월 12 일 | 담당교수: 한승현

Abstract. 본 보고서는 기업의 주요 경영 리스크인 직원 퇴사를 사전에 예측하고 선제적 인사 관리 체계를 구축하기 위한 기계학습 기반의 방법론을 제안한다. IBM HR Analytics 데이터셋(1,470 명)을 활용하였으며, 16.1%에 불과한 소수 퇴사자 비율로 인한 극심한 클래스 불균형 문제를 해결하기 위해 단순 정확도를 지양하고 PR-AUC, F1 score 와 Recall 등 다양한 지표들을 사용하였다. 조직심리학의 직무 요구-자원(JD-R) 관점을 차용하여 보상 적절성, 번아웃 위험도, 이직 성향 등의 도메인 특화 파생 변수를 생성한 후, Logistic Regression, Random Forest, XGBoost, LightGBM, TabNet 의 5 가지 모델을 구축하여 성능을 심층적으로 비교 분석하였다.

실험 결과, 전반적인 예측 안정성과 이탈 위험군 순위화 성능(PR-AUC 0.5869)에서는 선형 모델인 Logistic Regression 이 가장 우수하게 나타났다. 반면, 데이터의 복잡한 비선형 패턴을 파악하여 실제 퇴사자를 놓치지 않고 탐지하는 능력(Recall 0.6944)에서는 LightGBM 이 압도적인 성과를 기록했다. 이를 바탕으로 본 연구는 핵심 인재 이탈 방어가 최우선인 상황(LightGBM 활용)과 한정된 HR 자원의 효율적 타겟팅이 필요한 상황(Logistic Regression 활용)을 명확히 구분하는 투 트랙(Two-Track) 인사 운영 전략을 최종 제안한다.

Keywords: HR 애널리틱스, DDD, 인사 전략, 로지스틱 회귀, 랜덤 포레스트, XGBoost, LightGBM, TabNet

1. INTRODUCTION

1.1. 문제 배경과 동기

직원의 퇴사는 단순히 개인의 일탈적 선택이 아니라, 조직의 비용 증가와 안정성 저해로 직결되는 중대한 경영 문제다. 조직심리학의 직무 요구-자원(JD-R) 모델에 따르면, 과도한 연장 근무와 빈번한 출장 같은 '직무 요구' 요인이 보상 체계나 직무 만족도 같은 '직무 자원'을 압도하여 균형이 무너질 때 구성원은 번아웃을 겪고 최종적으로 퇴사를 결심하게 된다. 기존 인사 관리는 퇴사 의사 표명 후 진행하는 수동적 방식에 의존해 왔으나, 이는 실효성이 낮으므로 계량적 HR 데이터를 활용해 이탈 리스크를 사전에 포착하는 데이터 기반의 선제적 리텐션 체계 구축이 절실히 요구된다.

1.2. 해결하고자 하는 예측 및 분류 과제 정의

본 프로젝트는 글로벌 기업의 익명화된 인사 데이터인 IBM HR Analytics Dataset 을 바탕으로, 각 임직원의 특성을 파악하여 향후 조직을 이탈할 확률이 높은 고위험군을 식별하는 이진 분류 과제를 수행한다. 해당 데이터셋의 타겟 변수인 퇴사 여부(Attrition)는 잔류자(83.9%) 대비 퇴사자(16.1%)의 비중이 매우 적은 극심한 클래스 불균형 특성을 지니고 있다. 따라서 본 연구에서는 단순 정확도(Accuracy) 기준의 평가를 지양하고, 소수 클래스인 퇴사자 검출 성능을 객관적으로 비교할 수 있는 PR-AUC, F1-Score, Recall 의 최적화를 중속 과제로 정의하여 실험을 전개한다.

1.3. 프로젝트의 주요 목표와 기여 요약

본 프로젝트의 핵심 목표는 불균형 HR 데이터에서 퇴사 위험군을 정확히 예측하는 모델을 구축하고, 단순한 성능 비교를 넘어 비즈니스 의사결정 목적에 따른 최적의 모델 선택 기준을 제안하는 것이다. 구체적으로는 퇴사자를 놓치는 비용이 큰 '퇴사 방어 최우선' 상황과 한정된 자원을 정밀하게 타겟팅해야 하는 '자원 효율적 배분' 상황을 구분한 '투 트랙(Two-Track)' 모델 운영 전략을 제시한다. 이를 통해 조직심리학적 가설과 머신러닝 알고리즘을 결합하여 인재 유출을 선제적으로 방어할 수 있는 과학적 인사 관리 모델을 정립하고자 한다.

2. RELATED WORK

최근 기업 경영에서 인적 자원의 중요성이 커짐에 따라, 기계 학습을 활용해 이직을 미리 예측하는 선제적 대응에 관한 연구가 활발히 진행되고 있다. 기존 연구들은 주로 모델의 예측 성능 향상, 데이터의 신뢰성 확보, 그리고 이직 원인에 대한 해석 가능성에 집중하고 있다.

먼저 모델링 측면에서는 단일 모델의 한계를 극복하기 위해 앙상블 기법이 널리 사용된다. Alyousef et al.[7] 은 Random Forest, XGBoost, Logistic Regression 을 결합한 소프트 보팅(Soft Voting) 하이브리드 모델을 제안하여 높은 예측 성능을 달성했다. 이수정 및 곽대혁의 연구 [9]

에서도 동일한 조합의 앙상블 모델에 임계값 최적화(Threshold Tuning)를 적용하여 이직자 식별력을 단일 모델 대비 최대 3.2%p 향상시킨 사례가 있다. 또한 Karimi et al. [10] 은 AdaBoost 가 84~88%의 높은 정확도를 보이며 숙련 인력의 이직 예측에 효과적임을 입증했다

둘째, 데이터의 품질과 평가 프로토콜의 엄격함이 강조되고 있다. 이직 데이터셋의 고질적인 문제인 클래스 불균형을 해결하기 위해 SMOTE, ADASYN 과 같은 하이브리드 샘플링 전략이나 증화 추출 방식이 필수적으로 활용된다. 특히 Căvescu et al. [8]은 전처리 과정에서 테스트 데이터 정보가 유출되어 성능이 과대평가되는 것을 막기 위해 데이터 누수 방지 프로토콜을 제안하며 모델 평가의 신뢰성을 높이는 가이드라인을 제시했다.

셋째, 단순한 예측을 넘어 설명 가능한 AI(XAI)를 통해 이직의 핵심 원인을 규명하려는 시도가 이어지고 있다. SHAP(SHapley Additive exPlanations) 분석 등을 통해 공통적으로 도출된 주요 이직 동인은 시간 외 근무, 낮은 월 소득, 직무 만족도, 그리고 주식 옵션 수준이다 [7, 8, 9]. 관련 연구들은 특히 연차에 비해 직무 수준이 낮은 계층-경험의 정렬 불일치 상황이나, 미혼 직원의 낮은 복지 혜택 등이 이직 위험을 급격히 높인다는 차별화된 인사이트를 제공하고 있다.

본 프로젝트는 이러한 기존 연구들을 바탕으로 Logistic Regression 을 베이스라인으로 삼고, Random Forest 와 XGBoost 등 트리 기반 모델의 성능을 비교 분석하며, 이직에 영향을 미치는 주요 피처를 분석하여 실무적인 시사점을 도출하고자 한다.

3. APPROACH

3.1. 전체 문제 해결 전략 및 파이프라인 개요

본 프로젝트는 IBM HR Analytics 데이터를 활용하여 직원의 퇴사 여부를 예측하고, 이를 바탕으로 실제 HR 의사결정에 최적화된 모델 운영 전략을 수립하는 것을 목표로 한다. 전체 프로세스는 데이터 전처리, 조직심리학 기반의 피처 엔지니어링, 다양한 머신러닝/딥러닝 모델 학습 및 평가, 그리고 비즈니스 시나리오 기반의 모델 선정 순으로 진행된다. 특히 퇴사자 비중이 낮은(16%) 클래스 불균형 문제를 해결하기 위해 단순 성능 비교를 넘어 지표별 심층 분석을 수행하는 전략을 채택하였다.

3.2. 데이터 전처리 방법

모델의 학습 안정성과 일반화 성능을 높이기 위해 다음과 같은 전처리를 수행하였다.

- 데이터 분할: 전체 데이터를 학습(Train), 검증(Validation), 테스트(Test) 세트로 70:15:15 비율로 분할하였다. 이때 타깃 변수의 불균형을 고려하여 각 세트에서 퇴사자와 잔류자의 비율이 동일하게 유지되도록 Stratified Split 을 적용하였다.
- 불필요 열 제거: 모든 샘플의 값이 동일하거나 변별력이 없는 칼럼(예: Over18 등)을 제거하여 모델의 효율성을 높였다.
- 인코딩 및 스케일링: 범주형 변수는 모델 특성에 따라 One-Hot Encoding(Logistic Regression, XGBoost) 또는 Ordinal Encoding(기타 모델)을 적용하였으며, 수치형 변수는 변수 간 스케일 차이를 해소하기 위해 StandardScaler 를 사용하여 표준화했다.

3.3. 피처 엔지니어링 (Feature Engineering)

조직심리학의 직무 요구-자원(JD-R) 관점을 반영하여 퇴사 위험을 효과적으로 설명할 수 있는 파생 변수를 생성했다.

- 보상 적절성: 단순 소득이 아닌 경력, 근속 연수, 직급 대비 소득 수준을 산출하여 개인이 체감하는 보상의 수준을 수치화했다.
- 번아웃 및 직무 요구: 초과근무 여부와 통근거리, 워라밸 만족도를 결합하여 업무 부담으로 인한 이탈 위험도를 측정하는 변수를 설계했다.
- 조직 충성도 및 커리어: 현 직장 근속 비중을 통한 충성도, 총 경력 대비 이직 빈도를 통한 이직 성향, 그리고 승진 정체 정도를 나타내는 변수들을 추가했다.
- 종합 만족도: 환경, 직무, 관계 만족도와 워라밸 점수를 합산하여 직원이 느끼는 전반적인 조직 내 삶의 질을 반영했다.

분류	파생 피처	계산식
보상	Income_Per_WorkingYear	$\text{MonthlyIncome} / (\text{TotalWorkingYears} + 1)$
보상	Income_Per_YearAtCompany	$\text{MonthlyIncome} / (\text{YearsAtCompany} + 1)$
보상	Income_Per_Level	$\text{MonthlyIncome} / \text{JobLevel}$
보상	Cost_Effectiveness	$\text{PercentSalaryHike} / \text{PerformanceRating}$
번아웃	Overwork_Fatigue_Index	$\text{OverTime} \times \text{DistanceFromHome}$
번아웃	Burnout_Risk	$\text{OverTime} + (5 - \text{WorkLifeBalance})$
번아웃	JobSat_WLB_Interaction	$\text{JobSatisfaction} \times \text{WorkLifeBalance}$

경력 정제	Career_Velocity_Index	$\text{JobLevel} / (\text{TotalWorkingYears} + 1)$
경력 정제	Stagnation_Index	$\text{YearsSinceLastPromotion} / (\text{YearsAtCompany} + 1)$
만족도	Total_Satisfaction_Score	$\text{Environment} + \text{Job} + \text{Relationship} + \text{WorkLifeBalance}$
조직 충성도	Organizational_Loyalty_Ratio	$\text{YearsAtCompany} / (\text{TotalWorkingYears} + 1)$
이직 성향	Job_Hopping_Index	$\text{NumCompaniesWorked} / (\text{TotalWorkingYears} + 1)$

3.4. 사용 모델 및 알고리즘 설명

다양한 학습 알고리즘의 특성을 비교하기 위해 다음과 같이 총 5 가지 모델을 선정했다.

- Logistic Regression: 선형 관계를 바탕으로 퇴사 확률을 예측하며, 해석력이 높아 베이스라인 모델로 활용하였다.
- Random Forest [1]: 여러 결정 트리의 예측을 종합하는 배깅(Bagging) 기법을 사용하며, 변수 중요도 파악이 용이하고 과적합에 강한 특성이 있다.
- LightGBM [3] & XGBoost [2]: 이전 트리의 오차를 보완하며 학습하는 부스팅(Boosting) 계열 모델로, 정형 데이터 예측에서 높은 성능을 보인다. 특히 LightGBM 은 리프 중심 확장으로 학습 속도가 빠르다.
- TabNet [4]: Sequential Attention 메커니즘을 통해 정형 데이터에서 중요한 변수를 선택적으로 학습하는 딥러닝 모델로, 해석 가능성을 확보한 알고리즘이다. (상세 설명은 Appendix)

3.5. 하이퍼파라미터 및 평가지표 설정 근거

데이터의 클래스 불균형이 심하므로 단순 정확도(Accuracy) 대신 다음의 지표를 중점적으로 고려하였다.

- PR-AUC : 정밀도(Precision)와 재현율(Recall)의 관계를 나타내며, 소수 클래스인 퇴사자 탐지 성능을 순위화하여 평가하는 데 가장 적합한 지표로 판단하여 최우선 지표로 설정하였다.
- ROC-AUC : 모델이 실제 퇴사자와 잔류자를 얼마나 정확하게 구분해 내는지 전반적인 변별력을 평가하는 지표이다.

- Recall : 실제 퇴사자를 놓치지 않고 찾아내는 능력으로, 인재 유출 방지 비용이 큰 시나리오에서 핵심 지표로 활용된다.
- F1-Score : 정밀도(Precision)와 재현율(Recall)의 조화 평균을 측정하여, 클래스 불균형 상황에서 모델의 전반적인 분류 균형을 평가하는 지표로 활용하였다.
- Log Loss : 모델이 예측한 확률 값의 신뢰도를 평가하기 위해 보조 지표로 사용하였다.

4. EXPERIMENT

본 절에서는 실험 설계의 구체적인 내용과 사용된 데이터셋의 특성을 기술한다. 모든 모델이 동일한 조건에서 비교될 수 있도록 데이터 분할 방식, 실험 환경, 그리고 불균형 데이터에 특화된 평가 지표의 선정 근거를 명시한다.

4.1 Dataset

총 1,470 명의 직원 정보와 35 개의 변수로 구성된 IBM HR Analytics 데이터셋을 활용하였다. 타겟 변수인 퇴사 여부(Attrition)는 양성 클래스가 16.1%에 불과한 불균형을 가지고 있다. 피쳐 엔지니어링을 통해 '직급 대비 소득', '번아웃 위험도' 등의 새로운 피쳐를 설계하여 데이터셋을 보강하였다. 정확한 비교 평가를 위해, 전체 데이터를 학습 70%, 검증 15%, 테스트 15%의 비율로 분할하였다. 이때 타겟 변수의 비율에 맞게 Stratified 샘플링을 진행했고, random seed는 42로 동일하게 사용하였다. 하이퍼파라미터 튜닝 시에는 PR-AUC를 튜닝 목적 함수로 사용하였다. 평가 지표로는 PR-AUC, ROC-AUC, Recall, f-1 score, log loss와 Confusion Matrix를 사용했다.

항목	내용
데이터셋	IBM HR Analytics Employee Attrition & Performance (Kaggle 공개 데이터)
예측 목표	직원 정보 기반 퇴사 여부 예측
표본 수	1,470 개
피쳐 수	34 개
출처	URL: https://www.kaggle.com/datasets/pavansubhasht/ibm-hr-analytics-attrition-dataset License: Database: Open Database, Contents: Database Contents

4.2 Experimental Setup

항목	설정
데이터 분할	train 70% / val 15% / test 15%
평가 지표	PR-AUC, ROC-AUC, Recall, f-1 score, log loss, Confusion Matrix
베이스라인	Logistic Regression
비교 모델	Random Forest, XGBoost, TabNet, Light GBM
실험 환경	Python 3.12, scikit-learn 1.6.1, Pytorch 2.11.0, Optuna 4.9.0, random_state = 42

5. RESULTS

본 절에서는 실험을 통해 도출된 각 모델의 정량적 성과를 분석한다. 클래스 불균형이 심한 데이터 특성을 고려하여 PR-AUC를 주지표로 삼고, 실제 퇴사자 탐지력(Recall)과 예측 신뢰도(Log Loss) 등 다양한 지표를 통해 모델 별 우수성을 평가하였다.


5.1 정량적인 비교

모델	PR-AUC↑	ROC-AUC↑	Recall↑	F1-Score↑	Log Loss↓
Logistic Regression	0.5869	0.8315	<u>0.3611</u>	<u>0.4643</u>	0.3463
Random Forest	0.4181	0.7596	0.2778	0.3509	<u>0.4102</u>
LightGBM	<u>0.5260</u>	<u>0.8005</u>	0.6944	0.5000	0.4837
XGBoost	0.4755	0.7495	<u>0.3611</u>	0.4127	0.5260
TabNet	0.4153	0.7801	<u>0.3611</u>	0.4062	0.4556


표 1: 가장 좋은 성능을 보인 모델의 수치에는 **볼드체**를 두번째로 좋은 성능을 보인 모델의 수치에는 언더라인을 적용했다.

-모델 별 피쳐 중요도


Logistic Regression:




Random Forest:




LightGBM:



XGBoost:



TabNet:



5.2 지표별 주요 모델 성과 분석

- PR-AUC 및 전체적 안정성: Logistic Regression 이 모든 모델 중 가장 높은 0.5869 의 PR-AUC 를 기록하였다. 이는 데이터 규모가 작고 피쳐 간의 관계가 비교적 단순한 환경에서 선형 모델이 비선형 모델보다 더 뛰어난 일반화 능력을 갖추고 있음을 보여준다. 또한 Log Loss 역시 0.3463 으로 가장 낮아 예측 확률의 신뢰도가 가장 높았다.
- 재현율(Recall) 및 탐지력: LightGBM 은 0.6944 의 Recall 을 기록하여 실제 퇴사자 10 명 중 약 7 명을 정확히 식별해냈다. 이는 다른 모델들이 0.3 내외의 Recall 을 보인 것과 대조적이며, 퇴사자 누수를 최소화해야 하는 실무적 목적에 부합하는 결과이다.
- 기타 모델 성과: Random Forest 는 Recall(0.2778)에서 가장 낮은 성능을 보였는데, 이는 소수 클래스인 퇴사자 패턴을 안정적으로 학습하지 못한 결과로 분석된다. TabNet 과 XGBoost 는 각각 딥러닝과 부스팅의 강점을 기대하였으나, 본 실험의 데이터 규모(1,470 명) 하에서는 복잡한 구조로 인한 성능 이점이 제한적이었다.

5.3 소결

정량적 결과 분석을 통해, 단순히 하나의 지표가 모든 상황을 대변하지 않음을 확인하였다. 전체적인 분류 안정성은 Logistic Regression 이 우수하고, 특정 타겟 탐지력은 LightGBM 이 우수하므로, 이를 HR 현장의 의사결정 시나리오에 따라 선택적으로 활용하는 것이 타당하다는 근거를 확보하였다.

6. ANALYSIS / DISCUSSION

본 절에서는 실험 결과에 대한 심층적인 해석과 모델별 성능 차이의 원인을 분석한다. 또한, 프로젝트의 한계점을 검토하여 실무적 시사점과 향후 개선 방향을 도출한다.

6.1 모델별 성능 차이 및 원인 분석

실험 결과, 단순 선형 모델인 Logistic Regression(LR)이 PR-AUC(0.5869)와 Log Loss(0.3463) 면에서 가장 우수한 성과를 거두었다. 이는 다음과 같은 이유로 해석된다.

데이터 규모의 한계: 전체 샘플 수가 1,470 명으로 적고 퇴사자(Positive) 샘플이 237 명에 불과한 상황에서는, 복잡한 비선형 관계를 학습해야 하는 딥러닝(TabNet)이나 고도화된 앙상블 모델(XGBoost)보다 정규화된 선형 구조인 LR 이 과적합에 강하고 안정적인 일반화 성능을 보였다.

반면, LightGBM 은 재현율(Recall, 0.6944)에서 압도적인 성능을 보였다. 이는 리프 중심 분할 방식을 통해 변수 간의 복잡한 상호작용(예: 야근과 통근거리의 결합)을 효과적으로 포착하여 실제 퇴사자들을 민감하게 식별해냈기 때문이다.

6.2 주요 피처 및 모델 특성 해석

모델들이 공통적으로 중요하게 평가한 피처들은 직무 요구-자원(JD-R) 관점과 일치한다.

- 주요 변수: 모든 모델에서 초과근무(OverTime), 직무군(JobRole), 번아웃 위험도(Burnout_Risk), 종합 만족도(Total_Satisfaction_Score), 이직 성향(Job_Hopping_Index) 등이 상위 중요 피처로 도출되었다.
- 모델별 차이: LR 에서는 '출장 빈도'가 매우 중요한 변수로 작용했으나, LightGBM 에서는 '번아웃'과 '전반적 만족도'의 영향력이 더 크게 나타났다. 이는 기업 환경에 따라 모델 선택이 달라져야 함을 시사한다.

6.3 데이터 품질 및 실험 설계의 한계

- 데이터셋의 한계점: 본 데이터는 특정 기업의 익명화된 합성 데이터셋이므로 모든 기업 환경으로 일반화하기 어렵다. 또한 회사 외부 요인(노동 시장 상황, 동종 업계 처우 등)이 반영되지 않은 데이터라는 한계가 있다. 마지막으로 시계열 정보가 존재하지 않는다. 즉, 한 순간의 정보만을 담고 있는 데이터셋이기에 시간에 따른 피처들의 변화가 퇴사에 어떤 영향을 주었는지는 알 수 없다.

- 피처 엔지니어링의 효과: 다양한 파생 변수를 생성했으나 극적인 성능 향상으로 이어지지는 않았다. 이는 원본 변수가 이미 많은 정보를 담고 있거나, 작은 데이터 규모에서 파생 변수가 일부 노이즈나 중복 정보로 작용했을 가능성을 시사한다.

6.4 개선 방향 및 후속 연구

향후 연구에서는 다음과 같은 개선이 필요하다.

- 데이터 확장: 동종 업계의 처우 데이터나 외부 경제 지표를 추가하여 모델의 설득력을 높일 수 있다.
- 시계열 분석: 직원의 심리 상태나 보상 수준의 시간에 따른 변화를 반영하는 시계열 모델링을 통해 예측 시점을 최적화하는 연구가 가능할 것이다.

7. CONCLUSION

본 프로젝트는 IBM HR Analytics 데이터를 활용하여 기업의 인적 자원 관리에서 가장 치명적인 문제 중 하나인 직원의 퇴사 리스크를 데이터 기반으로 예측하고, 이를 실무 의사결정에 연결하는 모델링 과정을 수행하였다.

7.1. 프로젝트 요약 및 방법론

퇴사 예측은 단순히 "누가 퇴사할 것인가"를 맞히는 분류 문제를 넘어, 한정된 HR 자원을 누구에게 우선적으로 투입할지 결정하는 의사결정의 문제이다. 본 연구진은 직무 요구-자원(JD-R) 관점을 바탕으로 보상, 번아웃, 조직 충성도, 이직 성향 등을 반영한 피처 엔지니어링을 수행하였으며, Logistic Regression, Random Forest, LightGBM, XGBoost, TabNet 등 다양한 머신러닝 및 딥러닝 모델을 통해 성능을 검증하였다. 특히 16.1%에 불과한 소수 클래스(퇴사자) 탐지 성능을 객관적으로 평가하기 위해 PR-AUC, ROC-AUC, F1 score, Recall 등을 핵심 지표로 설정하여 실험을 전개하였다.

7.2. 주요 결과 및 실무적 의미

실험 결과, 전반적인 예측 안정성과 순위화 성능(PR-AUC 0.5869) 면에서는 Logistic Regression 이 가장 우수했으며, 실제 퇴사자를 놓치지 않고 찾아내는 능력(Recall 0.6944) 면에서는 LightGBM 이 압도적인 성과를 보였다. 이러한 결과를 바탕으로 본 프로젝트는 실제 HR 현장의 목적에 맞춘 투 트랙(Two-Track) 모델 운영 전략을 최종 제안하였다.

- 퇴사 방어 최우선 상황: 핵심 인재 유출을 막기 위해 퇴사자 누수를 최소화해야 할 때는 Recall 이 압도적으로 높은 LightGBM 을 활용하여 적극적으로 위험군을 탐지한다.

- 자원 효율적 배분 상황: 상담 인력이나 예산이 한정되어 정밀한 타겟팅이 필요할 때는 확률 예측의 신뢰도가 높은 Logistic Regression 을 활용한다.

7.3. 한계점 및 향후 확장 가능성

본 프로젝트는 단일 기업의 익명화된 데이터를 사용하였기에 모든 산업군으로 일반화하기에는 한계가 있으며, 외부 노동 시장의 변화나 시계열적 특성을 반영하지 못했다는 점이 아쉬움으로 남는다. 또한 작은 데이터 규모로 인해 복잡한 딥러닝 모델의 성능 이점이 충분히 발휘되지 못했으며, 파생 변수의 영향력이 기대보다 제한적이었다. 향후 연구에서는 동종 업계의 처우 정보나 외부 경제 지표를 통합하여 모델의 외부 타당성을 높이고, 직원의 심리 상태 변화를 추적하는 시계열 데이터를 결합한다면 더욱 정교한 선제적 인재 관리 시스템으로 확장될 수 있을 것이다. 이러한 데이터 기반의 접근은 주관적인 판단에 의존하던 인사 관리를 과학적인 경영 의사결정의 영역으로 한 단계 끌어올리는데 기여할 것으로 기대된다.


References

- [1] Breiman, L. (2001). Random forests. Machine learning, 45(1), 5-32.
- [2] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining (pp. 785-794).
- [3] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., ... & Liu, T. Y. (2017). Lightgbm: A highly efficient gradient boosting decision tree. Advances in neural information processing systems, 30.
- [4] Arik, S. Ö., & Pfister, T. (2021). Tabnet: Attentive interpretable tabular learning. Proceedings of the AAAI Conference on Artificial Intelligence, 35(8), 6679-6687.
- [5] Fawcett, T. (2006). An introduction to ROC analysis. Pattern recognition letters, 27(8), 861-874.
- [6] Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. PloS one, 10(3), e0118432.
- [7] Alyousef, Muna I., Hamza Wazir Khan, and Mian Usman Sattar. "A Hybrid Predictive Model for Employee Turnover: Integrating Ensemble Learning and Feature-Driven Insights from IBM HR Analytics." *Information* 17.2 (2026): 208.
- [8] Căvescu, Ana Maria, and Alina Nirvana Popescu. "Leakage-Free Evaluation for Employee Attrition Prediction on Tabular Data." *Information* 17.3 (2026): 308.
- [9] 이수정, and 곽대혁. "IBM HR 데이터를 활용한 직원 이직 예측 모델 구축 및 앙상블 기법 연구." *한국컴퓨터정보학회 학술발표논문집* 34.1 (2026): 19-22.
- [10] Karimi, Mahyar, and Kamyar Seyedkazem Viliyani. "Employee turnover analysis using machine learning algorithms." *arXiv preprint arXiv:2402.03905* (2024).


Appendix (Optional)

EDA 그래프:


회사 여부(Attrition) 타겟 변수 분포 및 불균형 확인




아근 여부(OverTime)에 따른 회사 분포



직무(JobRole)별 회사 상대 비율 (100% Stacked)








전체 수치형 변수간 상관관계 피어슨 행렬 (Heatmap)




TabNet : 정형 데이터(Tabular Data) 특화 딥러닝 모델이다. 기존 딥러닝 모델이 가진 블랙박스 한계를 극복하기 위해, 의사결정 나무의 순차적 분기 방식을 신경망으로 모방하였다. 모델 인코더 내부의 각 학습 스텝에서 Sparsemax(또는 entmax) 활성화 함수 기반의 어텐션 메커니즘을 적용하여 불필요한 노이즈 변수를 완벽히 차단하는 Built-in Feature Selection 을 수행한다. 마스크(Attention Mask)를 통해 변수 중요도를 확인할 수 있다.

Confusion Matrix :



PR-AUC 비교 그래프:



하이퍼파라미터 상세:

Random Forest:

```
n_estimators=300,  
max_depth=10,  
min_samples_split=2,  
min_samples_leaf = 4,  
class_weight='balanced',  
random_state=42,  
n_jobs=-1
```

XGBoost:

```
objective='binary:logistic',  
eval_metric='logloss',  
max_depth=5,  
learning_rate=0.09715958809614553,  
n_estimators=236,  
scale_pos_weight=pos_weight,  
random_state=42
```

LightGBM:

```
'class_weight': 'balanced',  
'colsample_bytree': 0.85,  
'learning_rate': 0.05,  
'max_depth': 2,  
'min_child_samples': 10,  
'min_split_gain': 0,  
'num_leaves': 3,  
'reg_alpha': 0.5,  
'reg_lambda': 1,  
'subsample': 0.7
```

TabNet:

```
n_d=16,  
n_a=16,  
n_steps=2,  
gamma=1.5643739715662777,  
lambda_sparse=0.0014106348309282917,  
optimizer_params=dict(lr=0.0496895157  
23358134),  
scheduler_params={"step_size":10,  
"gamma":0.9},  
mask_type='sparsemax',
```